

肺炎 X 光图像诊断识别

——《模式识别与机器学习》课程设计

课程：《模式识别与机器学习》课程设计

题目：选题 78 肺炎 X 光图像诊断识别

姓名：张龙骥 高金泽 张文博 李际宏 蔡沐河

指导老师：程骋

日期：2026-07-07

摘要

胸部 X 光图像常用于肺炎的辅助判断。本课程设计围绕“肺炎 X 光图像诊断识别”题目，完成了一个正常/肺炎二分类实验，内容包括数据检查、图像预处理、模型训练、测试评价、误差分析和网页演示。实验使用 Chest X-Ray Images (Pneumonia) 数据集。本地逐文件检查后，共得到 5856 张可读取图像，其中训练集 5216 张、验证集 16 张、测试集 624 张。

实验比较了 EfficientNetV2-S 和 Vision Transformer 两类模型。输入图像统一缩放到 224×224 ，并按 ImageNet 均值和标准差归一化；训练时加入随机水平翻转和小角度旋转。模型输出正常类和肺炎类概率，默认分类阈值设为 0.5。训练使用交叉熵损失和 AdamW 优化器，部分类别不平衡实验加入类别权重。

在默认阈值下，ImageNet 预训练 ViT-B/16 是本组实验中综合表现较好的模型，测试集 accuracy 为 0.9006，precision 为 0.8779，recall 为 0.9769，specificity 为 0.7735，F1 为 0.9248，ROC-AUC 为 0.9710。与 EfficientNetV2-S 无类别权重实验相比，ViT-B/16 将正常样本误报数从 91 降至 53，同时保持较高的肺炎召回率。原始 EfficientNetV2-S 在测试集阈值扫描中达到最高 F1 0.9527，但该阈值直接来自测试集预测结果，只适合做阈值权衡分析，不能作为无偏部署阈值。独立校准集实验显示，从训练集中划出的校准阈值没有稳定迁移到官方测试集，因此最终结论仍采用默认阈值结果。

Grad-CAM 结果显示，卷积模型在部分样本上会关注胸腔内部区域，但热力图只能辅助理解模型行为，不能当作医学病灶定位证据。课程设计还实现了单图上传网页演示，用于展示从上传胸片到输出分类概率的过程。综合默认阈值、误差结构和阈值分析，预训练 ViT-B/16 更适合作为本报告的主模型，EfficientNetV2-S 的测试集阈值扫描结果作为补充分析。实验结果只用于课程设计和研究训练，不构成临床诊断依据。

关键词：胸部 X 光；肺炎识别；二分类；EfficientNetV2；Vision Transformer；迁移学习

Abstract

Chest X-ray images are widely used as auxiliary evidence for pneumonia assessment. This course-design project builds a normal-versus-pneumonia classification experiment, covering data checking, preprocessing, model training, test evaluation, error analysis, and a local web demonstration. After local file-level checking, the Chest X-Ray Images (Pneumonia) dataset contains 5,856

readable images, including 5,216 training images, 16 validation images, and 624 test images.

Two model families are compared: EfficientNetV2-S and Vision Transformer. Images are resized to 224×224 , normalized using ImageNet statistics, and augmented during training by random horizontal flipping and small-angle rotation. The classifier predicts probabilities for the normal and pneumonia classes, and the default decision threshold is 0.5. Cross-entropy loss and AdamW optimization are used, with class weights tested in part of the experiments.

Among the compared models, the ImageNet-pretrained ViT-B/16 gives the strongest default-threshold result, with accuracy 0.9006, precision 0.8779, recall 0.9769, specificity 0.7735, F1 0.9248, and ROC-AUC 0.9710 on the test set. The original EfficientNetV2-S baseline reaches a higher threshold-swept F1 of 0.9527, but this threshold is selected from test-set predictions and is used only for trade-off analysis. Grad-CAM is used for qualitative interpretation of the CNN baseline, and a local web demo shows the single-image upload and prediction process. The experiment is limited to a pattern-recognition course project and is not a clinical diagnostic system.

Keywords: chest X-ray; pneumonia recognition; binary classification; EfficientNetV2; Vision Transformer; transfer learning

1 引言

肺炎是常见的呼吸系统疾病。胸部 X 光图像能够反映肺部阴影、纹理改变和局部浸润等影像特征，因此常被用于肺炎诊断的辅助判断。传统模式识别方法通常依赖人工设计纹理、边缘或灰度统计特征，而深度学习模型可以直接从图像中学习多层次视觉特征，在医学图像分类中已经成为常用技术路线之一 [3]。

本课程设计的任务是根据胸部 X 光图像判断样本属于正常类还是肺炎类。该问题可以形式化为二分类任务：输入一张胸片图像，输出两个类别的概率，再根据阈值给出最终类别。工作范围限定在课程设计实验，不面向临床诊断。

具体工作包括四部分：检查数据集文件和类别分布；训练并比较 EfficientNetV2-S 与 ViT-B/16；用混淆矩阵、误差率、概率分布、阈值扫描和 Grad-CAM 分析模型表现；最后把选定模型接入本地网页，展示单张胸片上传后的推理结果。已有研究已经将卷积网络和 Transformer 用于胸片肺炎检测 [4, 8]，本报告重点放在课程设计要求下的复现、比较和边界分析。

2 数据集与预处理

2.1 数据集组成

实验使用 Chest X-Ray Images (Pneumonia) 数据集。该数据集来自 Kermany 等发布的儿童胸部 X 光图像数据 [1, 2]。原始目录已经划分为训练集、验证集和测试集，并按正常类与肺炎类存放。文件夹名对应图像标签，可直接生成二分类标签。课程资料和公开页面中常见的总数表述为 5863；本地逐文件读取后，有 5856 张图像可以正常参与实验。后续统计和实验均以这一本地可读数量为准。样本数量如表 1 所示。

表 1: 数据集样本数量统计

数据划分	正常类	肺炎类	合计
训练集	1341	3875	5216
验证集	8	8	16
测试集	234	390	624
总计	1583	4273	5856

训练集中肺炎样本占 74.3%，正常样本占 25.7%，肺炎与正常样本数约为 2.89:1；测试集中肺炎样本占 62.5%，肺炎与正常样本数约为 1.67:1。训练集比测试集更偏向肺炎类别，模型可能因此更倾向于把样本判为肺炎。验证集只有 16 张图像，虽然正常类和肺炎类各 8 张，但样本量过小，不适合承担稳定的模型选择或阈值校准功能。因此，模型比较主要依据测试集结果，同时在结论中保留这一限制。

2.2 图像预处理

模型不能直接处理原始图像文件。实验中先将图像读取为三通道格式，再统一调整为 224×224 大小，并使用 ImageNet 的均值和标准差进行归一化。训练阶段加入随机水平翻转和小角度旋转，以增加样本变化；验证和测试阶段不使用随机增强，保证评估结果稳定。

这样处理后，每张胸片都被转换成固定尺寸的数值张量。模型实际学习的是图像中亮度、边缘、纹理、阴影分布和整体结构对应的数值模式。

3 方法

3.1 二分类基本原理

肺炎识别在本实验中被建模为二分类概率预测。对一张输入图像，模型输出正常类和肺炎类两个分数，再通过 softmax 转换为概率。默认判别规则为：若肺炎类概率满足 $P(\text{pneumonia}) \geq 0.5$ ，则预测为肺炎；否则预测为正常。

训练时，每张图像都有真实标签。如果真实标签为肺炎而模型给出的肺炎概率较低，交叉熵损失会变大；如果真实标签为正常而模型给出的肺炎概率过高，损失同样会变大。优化器根据损失函数对模型参数进行更新，使模型逐渐提高正确类别的概率，降低错误类别的概率。

模型没有采用人工规则去判断“哪里有阴影”。训练过程利用带标签胸片学习两类图像在统计特征上的差异，训练完成后形成从图像到类别概率的映射。

3.2 EfficientNetV2-S 模型

EfficientNetV2-S 属于卷积神经网络。卷积网络的特点是从局部区域开始提取特征：浅层更容易学习边缘、纹理和亮暗变化，深层会逐渐组合出更复杂的胸部结构和异常影像模式。实验使用 ImageNet 预训练的 EfficientNetV2-S，并将最后的分类层改为正常类和肺炎类两个输出。

选择 EfficientNetV2-S 的原因有两点。一是它在图像分类任务中具有较好的精度和计算效率平衡；二是卷积网络可以配合 Grad-CAM 进行可解释性可视化，便于观察模型在胸片上的大致关注区域。

3.3 Vision Transformer 模型

Vision Transformer 与卷积网络不同。它先将图像切分为若干小块，再将每个图像块转换为 token，通过 self-attention 建立不同区域之间的关系。以 ViT-B/16 为例，图像被划分为 16×16 的小块，模型可以同时参考左右肺野、上肺和下肺、肺部边缘以及整体胸腔结构。

Transformer 更擅长建模较长距离的区域关系，但从零训练通常需要更多数据。本任务数据规模有限，因此采用 ImageNet 预训练 ViT-B/16 进行微调。后续结果也显示，预训练对 ViT 路线影响很大。

3.4 训练与评价指标

EfficientNetV2-S 是 EfficientNet 系列的改进版本，设计目标是在精度、参数效率和训练速度之间取得更好的平衡 [5]。原始 EfficientNetV2-S 基线使用 ImageNet 预训练权重训练 3 个 epoch，batch size 为 32，初始学习率为 0.0003。ViT-B/16 采用 torchvision 提供的 ImageNet-1K 预训练权重训练 4 个 epoch，batch size 为 16，初始学习率为 0.00005。两类模型均使用 AdamW 优化器、余弦学习率调度和 0.0001 权重衰减，随机种子固定为 42。部分类别不平衡实验加入类别权重，未加权实验则使用普通交叉熵损失。

测试集共有 624 张图像，其中正常类 234 张，肺炎类 390 张。评价指标包括准确率、精确率、召回率、特异性、F1、ROC-AUC 和混淆矩阵。其中召回率反映肺炎样本被识别出来的比例，特异性反映正常样本被正确排除的比例。设 TP、TN、FP、FN 分别表示真阳性、真阴性、假阳性和假阴性，则 $\text{accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$ ， $\text{precision} = \text{TP} / (\text{TP} + \text{FP})$ ， $\text{recall} = \text{TP} / (\text{TP} + \text{FN})$ ， $\text{specificity} = \text{TN} / (\text{TN} + \text{FP})$ ， $\text{F1} = 2 \times \text{precision} \times \text{recall} / (\text{precision} + \text{recall})$ 。

医学图像分类不能只看单一指标。例如，模型更倾向于预测肺炎时，召回率可能提高，但正常样本误报也会增加。因此，报告同时观察召回率、特异性、混淆矩阵、假阳性率、假阴性率、平衡准确率和模型输出概率分布。新增的二次统计均由已保存预测结果和评估结果计算得到，不重新训练模型。

4 实验结果与分析

4.1 默认阈值结果

表 2 给出了默认阈值 0.5 下各模型在测试集上的结果。

表 2: 默认阈值下不同模型测试集结果

模型	Acc	Prec	Rec	Spec	F1	AUC
E-V2 原始	0.8173	0.7760	0.9949	0.5214	0.8719	0.9780
E-V2 无权重	0.8510	0.8100	0.9949	0.6111	0.8930	0.9626
ViT-S 随机	0.7949	0.7937	0.9077	0.6068	0.8469	0.8748
ViT-B 加权	0.9006	0.8779	0.9769	0.7735	0.9248	0.9710
ViT-B 无权重	0.8862	0.8537	0.9872	0.7179	0.9156	0.9676

表中 Acc、Prec、Rec、Spec 和 AUC 分别表示准确率、精确率、召回率、特异性和 ROC-AUC；E-V2 表示 EfficientNetV2-S。“加权”表示训练时加入类别权重，“无权重”表示使用普通交叉熵损失。ViT-S 随机表示没有成功加载外部预训练权重的 ViT-Small 对照实验。在这些模型中，预训练

ViT-B/16 加类别权重的默认阈值结果最好。它在测试集中正确识别 181 张正常图像和 381 张肺炎图像，误报 53 张正常图像，漏检 9 张肺炎图像。与 EfficientNetV2-S 无权重实验相比，ViT-B/16 的 F1 从 0.8930 提高到 0.9248，特异性从 0.6111 提高到 0.7735，正常样本误报明显减少。




图 1: ViT-B/16 测试集混淆矩阵

4.2 默认阈值误差结构与概率分布

默认阈值下，ViT-B/16 的主要优势在于减少正常样本误报。表 3 将混淆矩阵转换为假阳性率、假阴性率、平衡准确率和阴性预测值。假阳性率表示正常图像被误判为肺炎的比例，假阴性率表示肺炎图像被漏检的比例，平衡准确率可以减轻类别不平衡对 accuracy 的影响。

表 3: 默认阈值下的错误结构分析

模型	TN	FP	FN	TP	FPR	FNR	Bal-Acc	NPV
E-V2 原始	122	112	2	388	47.9%	0.5%	0.7581	0.9839
E-V2 无权重	143	91	2	388	38.9%	0.5%	0.8030	0.9862
ViT-S 随机	142	92	36	354	39.3%	9.2%	0.7573	0.7978
ViT-B 加权	181	53	9	381	22.6%	2.3%	0.8752	0.9526
ViT-B 无权重	168	66	5	385	28.2%	1.3%	0.8526	0.9711

EfficientNetV2-S 两个主要实验的假阴性率都很低，但正常样本误报率较高。E-V2 无权重实验的假阳性率为 38.9%，也就是 234 张正常测试图像中有 91 张被判为肺炎。ViT-B/16 加权模型的假阳性率为 22.6%，假阴性率为 2.3%。相较之下，它在正常误报和肺炎漏检之间更均衡。




图 2: 默认阈值误差率对比

按文件名中的肺炎类型继续统计，测试集肺炎图像包括 242 张细菌性肺炎和 148 张病毒性肺炎。ViT-B/16 加权模型在细菌性肺炎子集上识别出 238/242 张，漏检 4 张；在病毒性肺炎子集上识别出 143/148 张，漏检 5 张。随机初始化 ViT-Small 在两个肺炎子集上的漏检数更多，说明预训练对肺炎样本内部的识别稳定性也有帮助。表中的“148/148”只表示该测试子集没有漏检，不能说明模型在更大人群或新数据上也不会漏检。

表 4: 测试集肺炎子类型召回率

模型	细菌性识别/总数	细菌性漏检	病毒性识别/总数	病毒性漏检
E-V2 原始	240/242	2	148/148	0
E-V2 无权重	241/242	1	147/148	1
ViT-S 随机	218/242	24	136/148	12
ViT-B 加权	238/242	4	143/148	5
ViT-B 无权重	239/242	3	146/148	2

模型输出概率可以帮助定位部分错误来源。对 ViT-B/16 加权模型，真实正常样本的肺炎概率中位数为 0.0368，说明多数正常图像被赋予较低肺炎概率；但正常样本的第 90 百分位数达到 0.9691，说明仍有一部分正常图像被高置信度推向肺炎类。真实肺炎样本的肺炎概率中位数为 0.9996，大多数肺炎图像被明显区分出来。所有错误样本共 62 张，其中 35 张错误样本的预测置信度不低于 0.9。这类错误既包括阈值附近的摇摆样本，也包括高置信误判。

表 5: ViT-B/16 加权模型输出肺炎概率分布

真实类别	样本数	肺炎概率均值	P10	P50	P90	0.4-0.6 样本数
NORMAL	234	0.2588	0.0019	0.0368	0.9691	8
PNEUMONIA	390	0.9702	0.9810	0.9996	0.9999	3




图 3: ViT-B/16 测试集肺炎概率分布

4.3 阈值分析

默认阈值不一定是合适的操作点。降低阈值会让模型更容易判为肺炎，通常可以提高 recall，但正常样本误报会增加；提高阈值可能提高 specificity，但肺炎漏检也会增加。因此，报告扫描了不同肺炎概率阈值，用来观察模型分数的可调节空间。

表 6: 测试集阈值扫描结果

模型	阈值	Acc	Prec	Rec	Spec	F1
E-V2 原始	0.997	0.9407	0.9491	0.9564	0.9145	0.9527
E-V2 无权重	0.987	0.9135	0.9221	0.9410	0.8675	0.9315
ViT-B 加权	0.889	0.9087	0.9132	0.9436	0.8504	0.9281
ViT-B 无权重	0.686	0.9006	0.8779	0.9769	0.7735	0.9248

阈值扫描后，原始 EfficientNetV2-S 的测试集 F1 最高，达到 0.9527。预训练 ViT-B/16 在默认阈值下表现更好，但在同一测试集阈值扫描条件下没有超过 EfficientNetV2-S。两条路线的优势并不完全相同：ViT-B/16 适合作为默认阈值分类器，EfficientNetV2-S 的分数排序能力在该测试集上仍有较高上限。

以 ViT-B/16 加权模型为例，如果希望测试集召回率不低于 0.99，阈值需要降到 0.267，此时漏检降为 3 张，但误报增至 69 张；如果接受召回率约 0.95，阈值可升到 0.808，误报降为 41 张，但漏检增至 18 张。阈值选择本质上是在误报和漏检之间取舍，不能只追求某一个数值最大。

表 7: ViT-B/16 加权模型测试集阈值操作点

操作点	阈值	FP	FN	Rec	Spec	F1
recall $\geq$ 0.990	0.267	69	3	0.9923	0.7051	0.9149
recall $\geq$ 0.980	0.387	59	7	0.9821	0.7479	0.9207
recall $\geq$ 0.950	0.808	41	18	0.9538	0.8248	0.9265
test best F1	0.889	35	22	0.9436	0.8504	0.9281

上述阈值均来自测试集预测结果扫描，只能用于分析精确率、召回率和特异性之间的权衡，不能作为实际使用阈值。若要确定固定阈值，应先划分独立校准集，在校准集上选定阈值，再只用测试集做一次最终评价。




图 4: ViT-B/16 测试集阈值曲线

4.4 独立校准集尝试

为了检验训练集内部校准阈值是否能带来稳定提升，实验又从训练集中划出 10% 图像作为校准集，并用剩余训练图像重新训练 ViT-B/16。校准集没有参与该模型训练，可以用于选择阈值；官方测试集仍只用于最终检验。

校准集上的结果很高：默认阈值下 accuracy 为 0.9828，F1 为 0.9884；按平衡准确率选择阈值 0.814 后，校准集 specificity 提高到 0.9925，F1 为 0.9909。但把同一阈值应用到官方测试集后，结果没有超过原 ViT-B/16 默认模型，测试集 accuracy 为 0.8606，F1 为 0.8994。也就是说，校准集上的最优阈值没有稳定迁移到官方测试集。

表 8: 独立校准集阈值迁移结果

模型	阈值	Acc	Rec	Spec	F1	FP/FN
原 ViT	0.500	0.9006	0.9769	0.7735	0.9248	53/9
校准 ViT	0.500	0.8253	0.9974	0.5385	0.8771	108/1
校准 ViT	0.814	0.8606	0.9974	0.6325	0.8994	86/1

这个实验没有带来新的主结果提升，但说明了一个问题：当前数据划分下，训练集内划出的校准集比官方测试集更容易，直接用它确定阈值会低估正常样本误报风险。因此，最终仍采用原 ViT-B/16

默认阈值结果作为主结果，把校准实验作为限制分析。

4.5 模型二分类过程解释

从数据角度看，每张胸片都对应一个标签：正常或肺炎。模型训练时不断接收图像及其标签，通过交叉熵损失衡量预测概率与真实标签之间的差距。若预测错误，损失增大；反向传播会把这种误差信息传回模型各层，使参数朝着减少错误的方向更新。

从图像角度看，模型接收的是由像素值组成的张量。卷积网络从局部纹理和结构逐层组合特征，ViT-B/16 把图像划分为小块并建模不同区域之间的关系。两类模型最终都把图像信息转化为类别概率，二分类结果由两个类别概率和判别阈值共同决定。

5 可解释性分析

为观察卷积模型在不同样本上的关注区域，实验对 EfficientNetV2-S 进行了 Grad-CAM 可视化。Grad-CAM 利用目标类别相对于卷积特征图的梯度，估计图像区域对分类结果的贡献，并生成热力图 [7]。下图展示了 true positive、true negative、false positive 和 false negative 四类样本。




图 5: EfficientNetV2-S 测试样本 Grad-CAM 可视化

部分 true positive 样本的热区覆盖胸腔内部较大区域，说明模型使用了与胸部结构相关的信息。部分 false positive 样本中，模型对正常图像给出了较高肺炎概率，热区有时集中在局部胸腔区域或图像边缘，这与正常样本误报现象一致。false negative 样本的热图解释的是模型为什么倾向于正常类，不能解释为肺炎病灶位置。

Grad-CAM 可以帮助分析模型行为，但不能证明模型真正找到了医学病灶。本报告只将其作为定性解释材料，不作为临床证据。

6 单图上传网页演示

完成模型训练和测试后，课程设计制作了一个本地网页演示。这个页面不重新训练模型，只把已选定的 ViT-B/16 用于单张胸片推理。用户上传一张 X 光图片后，页面显示正常类概率、肺炎类概率和分类倾向。

网页由前端页面和本地推理服务组成。前端负责图片选择、影像预览和结果展示；后端读取上传图片，执行与测试阶段一致的预处理，再调用已训练的 ViT-B/16 做前向推理。用户选择图片后，页

面先显示影像预览；点击分类按钮后，图片被发送到本地服务；后端将图片转换为三通道格式，统一缩放到 224×224 ，并按 ImageNet 均值和标准差归一化；模型输出正常类和肺炎类分数，经 softmax 转换为概率。演示页面使用默认阈值 0.5，当肺炎概率不低于该阈值时显示为疑似肺炎，否则显示为未见肺炎模式。

下图展示了网页的两种输出状态。左侧为正常样本，模型输出正常概率为 90.7%，肺炎概率为 9.3%，页面显示为未见肺炎模式；右侧为肺炎样本，模型输出肺炎概率为 99.5%，页面显示为疑似肺炎。两张图说明网页可以完成单图上传、影像预览、概率输出和分类提示。该结果只代表模型在示例样本上的分类倾向，不能解释为真实临床诊断结论。




图 6: 单图上传网页正负样本并排展示

网页演示保留了课程设计结果的边界：不重新选择阈值，不使用测试集信息修改模型，也不把输出包装成医疗诊断。页面中提示结果仅用于课程设计演示；若实际存在症状或检查异常，应咨询专业医生。这样可以展示模型推理过程，也避免夸大实验模型的能力。

7 讨论

实验结果显示，预训练对该任务影响很明显。随机初始化 ViT-Small 的默认 F1 为 0.8469，预训练 ViT-B/16 的默认 F1 为 0.9248。对于 5856 张规模的胸片数据，直接从零训练 Transformer 并不占优，利用自然图像预训练权重进行迁移学习更合适。这也与 ViT 原始工作中“预训练后迁移到下游图像识别任务”的思路一致 [6]。

默认阈值和阈值扫描回答的是两个问题。默认阈值表现代表模型在不额外调阈值时的直接表现；阈值扫描反映模型分数在特定测试集上的可调节空间。在本组实验中，ViT-B/16 的默认阈值结果最好，EfficientNetV2-S 则在测试集阈值扫描后取得最高 F1。AUC 较高也不能自动等同于固定阈值表现最好，因为最终分类仍取决于阈值选择以及误报、漏检之间的取舍。

误差分析也说明，模型表现不能只用 F1 概括。ViT-B/16 加权模型是默认阈值下的主结果，但仍有 53 张正常图像被误报为肺炎，其中一部分还是高置信误报。对课程设计而言，这已经能说明模型具备一定的二分类能力；对真实医学场景而言，模型输出仍需要人工复核，高置信概率不能直接等同于诊断事实。

当前实验有几个限制。第一，验证集只有 16 张图像，不能承担稳定的模型选择或阈值校准功能。第二，训练集和测试集的类别比例并不完全一致，训练集肺炎比例更高，可能影响模型对肺炎类别的倾向。第三，测试集阈值扫描存在信息泄漏风险，只能作为分析，不能写成最终部署策略。第四，数据集中没有病灶级标注，Grad-CAM 热区不能解释为准确病灶定位。

为避免直接使用测试集选择阈值，实验尝试从训练集中划出独立校准集来选择 ViT-B/16 阈值。

结果显示，校准集上的高分没有转化为官方测试集提升。现有结果足以支撑课程设计中的模型比较，但不足以支撑“已经获得稳定部署阈值”的说法。若继续改进，更应引入可靠的验证/校准数据，或做多次随机划分稳定性实验；继续在同一个测试集上寻找更高的阈值扫描分数意义有限。

8 结论

本课程设计完成了肺炎 X 光图像二分类实验。数据集完整性检查显示，本地共包含 5856 张有效胸片。EfficientNetV2-S 和 ViT-B/16 两条路线均能完成从图像输入到正常/肺炎概率输出的分类任务。

在默认 0.5 阈值下，预训练 ViT-B/16 加类别权重取得本组实验中最好的综合结果：accuracy 0.9006, precision 0.8779, recall 0.9769, specificity 0.7735, F1 0.9248, ROC-AUC 0.9710。相比 EfficientNetV2-S 无类别权重实验，它明显减少正常样本误报，并保持较高肺炎召回率。

在测试集阈值扫描中，原始 EfficientNetV2-S 取得最高 F1 0.9527，说明其分数排序能力仍然较强。由于该阈值来自测试集扫描，不能被表述为实际使用阈值。综合默认阈值和误差结构，预训练 ViT-B/16 更适合作为本报告的主模型，EfficientNetV2-S 的扫描结果保留为阈值权衡分析。

独立校准集实验没有提升官方测试集结果，因此报告保留 ViT-B/16 默认阈值作为主模型结论，并明确阈值校准受数据划分限制。该结果可以满足课程设计对实验流程、模型比较和误差分析的要求，但不能扩展为临床部署结论。

应用展示部分实现了本地网页演示，支持单张 X 光图片上传、影像预览、模型推理和概率展示。网页只用于课程设计展示，不用于临床诊断。

参考文献

1. Kermany D, Zhang K, Goldbaum M. Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification. Mendeley Data, V2, 2018. DOI: 10.17632/rscbjbr9sj.2.
2. Kermany D S, Goldbaum M, Cai W, et al. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. Cell, 2018, 172(5): 1122-1131.e9. DOI: 10.1016/j.cell.2018.02.010.
3. Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis. Medical Image Analysis, 2017, 42: 60-88. DOI: 10.1016/j.media.2017.07.005.
4. Rajpurkar P, Irvin J, Zhu K, et al. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning. arXiv:1711.05225, 2017. DOI: 10.48550/arXiv.1711.05225.
5. Tan M, Le Q V. EfficientNetV2: Smaller Models and Faster Training. Proceedings of the 38th International Conference on Machine Learning, 2021: 10096-10106.
6. Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021.
7. Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. ICCV, 2017: 618-626. DOI: 10.1109/ICCV.2017.74.
8. Singh S, Kumar M, Kumar A, et al. Efficient pneumonia detection using Vision Transformers on chest X-rays. Scientific Reports, 2024, 14: 2487. DOI: 10.1038/s41598-024-52703-2.