

基于深度学习的胸部 X 光肺炎分类

患者级数据审计、可靠性评价与跨数据集泛化研究

张龙骥 高金泽 张文博 李际宏 蔡沐河

指导教师：程骋

课程：模式识别与机器学习

2026 年 7 月

摘要

胸部 X 光图像肺炎分类是医学图像模式识别中的典型二分类问题，也常被用于迁移学习课程实验。公开数据集上的较高分数并不自动表示模型具有稳定的跨人群或跨机构能力：训练集与测试集可能共享患者，验证集可能过小，外部数据的标签语义也可能不同。若不先处理这些问题，继续增加模型或调节阈值会放大不可靠结论。

本课程设计建立了覆盖数据完整性审计、患者级重划分、多模型训练、外部评价、概率校准、错误分析和网页演示的可复现实验流程。项目首先审计 Kermany 儿童胸片数据的 5856 张图像。字节级哈希未发现精确图像跨集合重复，但依据文件名解析的肺炎患者编号有 170 个同时存在于官方训练集与测试集。为保证评价独立性，项目汇总原有目录后按患者分组，重新划分为 4107 张训练图像、579 张验证图像和 1170 张锁定内部测试图像；三个集合的患者标识完全隔离。RSNA 镜像可用子集包含 1707 张图像，测试集为 442 张；NIH 弱标签子集包含 130 张图像，仅用于敏感性分析。

严格基线比较 DenseNet121、ConvNeXt-Tiny 与 ViT-B/16，每种模型运行三个随机种子。三模型集成在患者级内部测试集上的准确率为 0.9778–0.9821、ROC-AUC 为 0.9945–0.9968，95% 患者级 bootstrap 区间高度重叠。直接迁移至 RSNA 后，准确率下降到 0.6674–0.6765，平衡准确率下降到 0.6591–0.6695，说明数据来源差异的影响远大于三种结构之间的差异。仅使用亮度、灰度分布、边缘和中心区域统计量的来源分类器，其五折组间验证 AUC 达到 0.9551，表明两个数据来源存在明显、可测量的图像风格差异。

低成本稳健训练在 DenseNet121 上加入轻度强度扰动和 0.1 标签平滑。三个随机种子的 RSNA 平衡准确率均值由严格基线提高到 0.7116，内部平衡准确率保持在 0.9742；但 RSNA AUC 降至 0.7826，说明该方案改善了固定阈值行为和概率分布，却没有全面改善排序能力。项目据此把结果表述为部分改善，并继续比较患者级混合训练与域均衡采样。所有阈值与温度参数只允许从验证数据学习，测试集阈值扫描仅用于事后说明误报和漏检的权衡。

实验表明，课程设计最重要的提升并非增加网络数量，而是把数据独立性、外部标签差异、随机波动和概率可靠性纳入同一证据链。本项目只研究公开胸片的图像级二

分类，不构成临床诊断、病灶定位或治疗依据。

关键词：胸部 X 光；肺炎分类；数据泄漏；患者级划分；外部验证；概率校准；域偏移

Abstract

Chest radiograph pneumonia classification is a representative binary pattern-recognition task, but high performance on a public split does not by itself imply reliable generalization. This project develops an auditable pipeline covering data-integrity checks, patient-grouped splitting, multi-model training, external evaluation, calibration, error analysis, and a local web demonstration. An audit of 5,856 Kermany images found no exact cross-split duplicate files but identified 170 pneumonia subject identifiers shared by the official training and test folders. A new patient-grouped split was therefore frozen with 4,107 training, 579 validation, and 1,170 locked internal-test images.

DenseNet121, ConvNeXt-Tiny, and ViT-B/16 were trained with three random seeds. Their ensemble accuracies on the patient-independent internal test set ranged from 0.9778 to 0.9821, whereas accuracy on the 442-image RSNA external test set fell to 0.6674–0.6765. A source classifier based only on simple image statistics achieved a grouped cross-validation AUC of 0.9551, confirming measurable acquisition and style differences. A low-cost robust DenseNet training recipe improved mean external balanced accuracy to 0.7116 while preserving internal performance, but reduced external ROC-AUC; it is therefore interpreted as a partial operating-point improvement rather than a universal gain. The work demonstrates why split integrity, uncertainty, and external label semantics must be examined before model rankings are accepted. The system is intended solely for coursework and research training and is not a clinical diagnostic tool.

Keywords: chest radiograph; pneumonia classification; data leakage; patient-level split; external validation; calibration; domain shift

目录

摘要	I
Abstract	III
第一章 绪论	1
1.1 研究背景	1
1.2 原项目状态与审查动机	1
1.3 研究问题	2
1.4 主要工作	2
1.5 本文结构	3
第二章 理论基础与相关工作	4
2.1 图像二分类	4
2.2 卷积网络与 Transformer	4
2.3 迁移学习与类别不均衡	5
2.4 患者级数据泄漏	5
2.5 域偏移与数据捷径	5
2.6 判别、校准与操作点	6
2.7 模型解释的边界	6
2.8 报告规范	6
2.9 为什么高内部准确率仍可能不可靠	7
2.10 评价指标之间为何会冲突	7
2.11 课程设计中的负结果	7
第三章 数据集、任务定义与完整性审计	9

3.1	任务定义	9
3.2	Kermany 儿童胸片	9
3.3	RSNA 外部数据	10
3.4	NIH 弱标签子集	10
3.5	审计方法	10
3.6	审计结果	11
3.7	患者级重划分	11
3.8	数据集差异与混杂	12
3.9	患者标识解析的误差边界	13
3.10	文件哈希与感知重复	13
3.11	标签转换的具体风险	13
3.12	数据门禁的可维护性	14
第四章	方法与系统设计	15
4.1	总体流程	15
4.2	图像预处理	15
4.3	DenseNet121	16
4.4	ConvNeXt-Tiny	16
4.5	ViT-B/16	16
4.6	损失函数和优化	16
4.7	随机性控制	17
4.8	混合训练与域均衡	17
4.9	概率校准与阈值	17
4.10	错误分析与 Grad-CAM	18
4.11	网页演示	18
4.12	参数量、计算量与比较公平性	18
4.13	checkpoint 选择与过拟合	19
4.14	域策略的目标函数解释	19
第五章	实验协议与统计方法	21
5.1	实验环境	21
5.2	数据职责	21

5.3	实验矩阵	22
5.4	评价指标	23
5.5	多随机种子	23
5.6	患者级 bootstrap	23
5.7	成功标准	24
5.8	完整性门禁	24
5.9	研究解释规则	24
5.10	实验注册表与命名规则	24
5.11	比较机会与测试集治理	25
5.12	bootstrap 实现细节	25
5.13	计算预算与环境记录	25
第六章	患者级内部基线与协议影响	27
6.1	旧官方划分复现	27
6.2	患者级严格基线	27
6.3	三 seed 集成与置信区间	28
6.4	为什么新划分分数更高	28
6.5	配置漂移修复的影响	29
6.6	内部结果小结	29
6.7	逐 seed 结果与稳定性解释	29
6.8	类别比例与 accuracy 解释	30
6.9	错误数量的实际含义	30
第七章	外部泛化与数据域差异	31
7.1	直接迁移设置	31
7.2	RSNA 三模型结果	31
7.3	外部集成与不确定性	31
7.4	来源分类诊断	32
7.5	概率与错误结构变化	32
7.6	NIH 弱标签敏感性分析	33
7.7	外部结果小结	33
7.8	内部到外部的指标变化	33

7.9	来源分类器的五折结果	34
7.10	标签偏移与协变量偏移	34
7.11	为什么 NIH 不能补足第三外部验证	34
第八章	稳健训练与跨域策略实验	35
8.1	实验目的	35
8.2	低成本稳健训练	35
8.3	简单混合训练	36
8.4	域均衡采样	36
8.5	与旧适配实验的关系	37
8.6	为何不继续堆叠复杂域方法	37
8.7	本章结论	38
8.8	三种策略的效果分解	38
8.9	验证集表现与 test 一致性	38
8.10	有监督适配的实际含义	39
8.11	失败方案的保留规则	39
第九章	概率可靠性、阈值与错误解释	40
9.1	同来源内部校准	40
9.2	RSNA 目标域校准	40
9.3	validation 冻结阈值	41
9.4	错误样本结构	42
9.5	Grad-CAM 解释	42
9.6	本章结论	43
9.7	温度参数的逐 seed 稳定性	43
9.8	ECE 的解释限制	43
9.9	阈值跨 seed 变化的来源	43
9.10	错误案例如何避免挑选偏差	44
第十章	演示系统与软件质量验证	45
10.1	系统目标与边界	45
10.2	系统结构	45

10.3 模型与权重	45
10.4 异常处理	46
10.5 自动测试	46
10.6 复现入口	46
10.7 软件边界	46
第十一章 综合讨论与有效性威胁	47
11.1 患者级审计改变了什么	47
11.2 模型结构与数据覆盖	47
11.3 低成本稳健方案的双面结果	47
11.4 域均衡为何未胜出	48
11.5 内部有效性威胁	48
11.6 构念有效性威胁	48
11.7 外部有效性威胁	49
11.8 统计结论威胁	49
11.9 工作量与课程价值	49
11.10 后续工作	49
11.11 对导师可能质疑的直接回应	50
11.11.1 为什么患者级新划分仍然高达 98%	50
11.11.2 既然官方 test 有患者交叉, 旧结果是否全部作废	50
11.11.3 为什么不把简单混合称为域泛化	50
11.11.4 为什么不继续做更多模型和复杂算法	50
11.11.5 50 页是否仍在凑篇幅	50
11.12 研究诚信与协作边界	51
第十二章 结论	52
附录 A 复现与验收附录	56
A.1 环境安装	56
A.2 患者级划分与审计	56
A.3 严格训练示例	56
A.4 结果聚合	57

A.5 校准	57
A.6 网页演示	57
A.7 关键产物	58
A.8 最终验收表	58

表格

3.1	Kermany 官方目录图像统计	9
3.2	RSNA 镜像可用子集统计	10
3.3	完整性审计摘要	11
3.4	Kermany 患者级新划分	12
3.5	三个数据来源的关键差异	12
5.1	数据集合职责与允许操作	22
6.1	Kermany 官方目录复现结果（探索性历史基线）	27
6.2	患者级 locked test 三 seed 结果（均值 $\pm$ 标准差）	28
6.3	三 seed 概率集成的患者级内部结果	28
7.1	Kermany 训练模型在 RSNA test 上的三 seed 结果	31
7.2	Kermany 与 RSNA 简单图像统计均值	32
8.1	严格基线与低成本稳健训练三 seed 比较	35
8.2	简单混合训练三 seed 结果（均值 $\pm$ 标准差）	36
8.3	域均衡训练三 seed 结果	37
9.1	DenseNet 内部概率校准（三 seed 均值）	40
9.2	RSNA 目标域校准（三 seed 均值）	41
9.3	RSNA validation 选择 balanced accuracy 阈值后的 test 结果	41
9.4	代表性 seed42 错误结构	42

第一章 绪论

1.1 研究背景

深度学习能够从图像像素中学习多层次表示，已经成为医学图像分类研究的常用工具 [7]。在课程设计场景中，胸部 X 光正常/肺炎分类同时涉及图像预处理、类别不平衡、迁移学习、阈值决策和模型解释，能够覆盖模式识别课程中的主要知识点。Kermany 等公开的儿童胸片数据规模适中、目录结构清楚，因此被大量教学项目采用 [6, 5]。

任务容易实现，不等于结论容易成立。一个模型可能在指定测试目录中获得很高准确率，却在另一个医院或另一种标签体系中明显下降。Zech 等对跨机构胸片模型的研究已经表明，来源变化会导致肺炎检测性能显著波动 [14]。这种变化可能来自患者年龄、疾病谱、设备、体位、后处理、标签定义或采集流程。模型也可能利用边框、文字、灰度风格等与疾病无直接关系的线索。

另一类问题来自实验协议。同一患者可能拥有多张影像，如果这些影像分别进入训练和测试，模型有机会利用患者稳定特征。验证集过小会使 checkpoint、阈值和温度参数对少量样本过度敏感。反复查看测试结果再修改方案，也会让测试集逐渐承担验证集功能。此时数字仍可被代码准确计算，但研究解释已经产生偏差。

1.2 原项目状态与审查动机

原项目已完成 ViT-B/16、DenseNet121 和 ConvNeXt-Tiny 的训练评价，并在 Kermany 官方测试目录上报告约 0.89–0.91 的准确率。项目还扩充了 RSNA 镜像子集，完成混合训练、域均衡、冻结与解冻微调、温度缩放、错误分析和 Grad-CAM。工程产物较完整，但存在三个疑问：第一，数据划分是否真正患者独立；第二，不同模型的配置和权重记录是否一致；第三，51 页报告是否由正文研究内容支撑。

全面审查确认，40 份带预测 CSV 的评价 JSON 均可复算，主 ViT 权重哈希也与发布说明一致。然而，Kermany 肺炎文件名有 170 个患者编号跨越官方训练和测试目录；公开 ViT 配置一度又与发布权重内嵌的真实学习率不一致。PDF 逐页文本审计显

示，第 20–50 页主要是一页一图的附录。这些问题不会让所有旧结果自动失效，但足以要求重新建立证据等级。

1.3 研究问题

本文围绕四个可回答的问题组织实验：

- RQ1: Kermany 官方目录中的患者交叉会怎样影响评价可信度，怎样建立可审计的患者级划分？
- RQ2: 在患者独立的内部测试上，三种代表性结构的判别能力、稳定性和概率误差有何差异？
- RQ3: 从儿童胸片迁移到 RSNA 外部数据后，性能下降表现在哪里，数据来源差异能否被简单统计量识别？
- RQ4: 轻量稳健训练、混合训练和域均衡采样能否提高外部性能，同时控制内部性能损失？

这四个问题把“模型跑通”推进到“结论是否可信”。它们仍属于课程设计范围，不试图回答临床诊断准确性或真实医疗效益。

1.4 主要工作

本文实际完成的工作包括：

1. 开发只读完整性审计工具，对数据患者编号、文件哈希、标签冲突和评价结果进行机器检查；
2. 汇总 Kermany 全部图像，按患者标识分组并固定新的 train/validation/locked test manifest；
3. 修正随机性设置、seed 接口和 ViT 配置漂移，重新运行三模型三随机种子基线；
4. 在 RSNA 外部测试集和 NIH 弱标签集合上区分主要评价与敏感性分析；
5. 用患者级 bootstrap 区间、多 seed 均值和配对预测文件表达不确定性；
6. 设计数据来源分类和图像统计诊断，检验域差异是否可被非病理线索识别；

7. 比较稳健增强、标签平滑、简单混合和域均衡采样的双域效果；
8. 统一阈值、校准、错误分析和网页演示的复现边界。

1.5 本文结构

第 2 章介绍模型、域偏移、校准与患者级评价基础；第 3 章说明三个数据集及完整性审计；第 4 章给出模型和训练方法；第 5 章定义实验与统计协议；第 6–9 章依次报告内部基线、外部泛化、稳健训练和可靠性分析；第 10 章说明演示系统；第 11 章讨论结论有效性；第 12 章回答研究问题并总结交付。

第二章 理论基础与相关工作

2.1 图像二分类

设输入胸片为 x ，真实标签 $y \in \{0, 1\}$ ，其中 0 表示阴性类，1 表示肺炎类。模型 f_θ 输出两个 logit z_0, z_1 ，softmax 将其转换为概率：

$$p(y = k | x) = \frac{\exp(z_k)}{\exp(z_0) + \exp(z_1)}. \quad (2.1)$$

默认决策以 $p(y = 1 | x) \geq 0.5$ 判为肺炎。概率排序、固定阈值分类和概率可信度是三个不同层面：AUROC 关心排序，混淆矩阵指标依赖阈值，Brier score 和 ECE 关心概率与实际结果的一致程度。

2.2 卷积网络与 Transformer

DenseNet 通过密集连接复用前面各层特征，改善梯度传播并控制参数规模 [4]。胸片中的局部纹理、肺野结构和边缘变化适合卷积特征提取，因此 DenseNet121 被选为主 CNN 基线。ConvNeXt 在卷积框架内吸收分层设计、大卷积核和现代训练经验，用作现代 CNN 对照 [8]。

ViT 把图像划分为固定大小 patch，将 patch 嵌入与位置编码送入 Transformer 编码器，通过自注意力建模较长距离关系 [2]。ViT 参数较多，对预训练和学习率敏感。本项目曾因配置文件学习率与发布权重真实设置不一致，得到明显欠拟合结果。这一事件说明，架构名称不能代替完整训练配方；模型比较必须同时披露初始化、优化器、学习率、batch size、epoch 和 checkpoint 选择规则。

2.3 迁移学习与类别不均衡

训练集规模不足以支持所有模型稳定从零学习，因此三模型均从 ImageNet 权重初始化。迁移学习并不意味着自然图像特征与胸片完全匹配，只表示提供较好的参数起点。训练集肺炎图像多于阴性图像，普通交叉熵可能偏向多数类。加权交叉熵写为

$$\mathcal{L}_{CE} = -w_y \log p(y | x), \quad (2.2)$$

其中 w_y 与类别频数反比。类别权重可改善少数类学习，也可能改变概率校准和固定阈值行为，因此必须同时报告召回率、特异度和 Brier score。

标签平滑把硬标签替换为接近 0 和 1 的软目标，抑制过度自信。MixUp 则对图像和标签做凸组合 [15]。本项目正式低成本方案采用轻度亮度/对比度扰动与 0.1 标签平滑，目的不是构造复杂新模型，而是检验减少风格依赖能否改善外部固定阈值结果。

2.4 患者级数据泄漏

医学影像的统计单位通常是患者，而不是图像。同一患者的多次拍摄包含稳定的解剖、体型和采集信息。若以图像为单位随机划分，同一患者可能跨越训练和测试，独立同分布假设被破坏。即使文件内容不完全相同、标签也一致，模型仍可能借助患者特征降低测试难度。因此，数据审计必须同时检查精确文件重复和患者标识交叉。

患者级划分也不能自动保证外部有效性。一个数据集内部的患者虽然独立，采集医院、人群和标签规则仍可能相同。患者级内部评价回答“对同来源未见患者是否有效”，外部评价回答“面对来源变化是否仍有效”，两者不能互相替代。

2.5 域偏移与数据捷径

域偏移指训练与评价数据的联合分布不同。胸片中常见来源包括设备、视图、年龄、灰度映射、压缩方式、边框和疾病定义。Zech 等发现，肺炎模型跨医院的泛化表现具有明显差异 [14]。模型还可能利用与标签偶然相关的来源线索，这类线索在开发集上有效，却不会稳定迁移。

本文用两类证据检查域偏移。一类是直接比较内部和 RSNA 外部指标；另一类是只用简单图像统计训练来源分类器。如果均值、分位数、边缘亮度和中心纹理就能区分来源，则至少说明数据风格差异明显。高来源分类 AUC 并不能证明某个具体因素导致肺炎误判，但能够否定“两个数据集除疾病标签外基本一致”的假设。

混合训练把多个来源直接合并；域均衡采样让每个来源贡献近似相同的采样概率；CORAL 等方法进一步对齐特征二阶统计 [12]。越复杂的方法越需要严格验证，否则可能通过目标域开发数据获得局部收益，却损害未见来源。

2.6 判别、校准与操作点

准确率受类别比例影响。平衡准确率定义为召回率与特异度的平均：

$$\text{BAcc} = \frac{1}{2}(\text{Sensitivity} + \text{Specificity}). \quad (2.3)$$

F1 强调阳性类 precision 和 recall, 不能反映阴性误报全貌。AUROC 衡量排序, AUPRC 更受阳性率影响。本文同时报告多项指标，避免单一数字替代完整误差结构。

Brier score 为概率与二值结果的均方误差：

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2. \quad (2.4)$$

ECE 把样本按置信度分箱，计算箱内准确率与平均置信度差的加权和。ECE 依赖分箱方式，小样本时尤其不稳定。温度缩放用单一正参数 T 缩放 logit，并在验证集上最小化负对数似然 [3]。它通常不改变排序，但会改变概率和固定阈值结果。

2.7 模型解释的边界

Grad-CAM 根据目标类别梯度对卷积特征图加权，得到输入区域对当前预测的贡献热图 [10]。热图能帮助检查模型是否关注图像边缘或胸腔区域，却不提供病灶真值。没有框或分割标注时，热区不能被称为病灶定位；即使与 RSNA 框重叠，也只能作粗粒度一致性分析。

2.8 报告规范

TRIPOD+AI 强调完整报告数据来源、参与者、结局、模型构建、内部评价、性能指标和不确定性 [1]；PROBAST+AI 用于检查预测模型研究的偏倚和适用性风险 [9]。本报告是课程设计，不宣称遵循临床研究注册流程，但借鉴其透明性要求，区分开发数据、内部测试和外部评价，并报告失败结果与限制。

2.9 为什么高内部准确率仍可能不可靠

内部准确率同时受任务可分性、数据重复、标签噪声和划分方式影响。若训练与测试来自相同采集流程，模型可能学习一组在该流程内稳定、在外部流程中无效的相关特征。例如，某类图像更常出现特定裁剪范围，模型可以利用胸腔外背景间接预测标签。它在内部 test 上仍是“真正未见图像”，却没有学习预期医学构念。

评价可靠性至少包含三层。第一层是数据独立性：同一患者和同一文件不能跨集合。第二层是方案独立性：test 不能反复参与超参数和模型选择。第三层是来源独立性：至少一个外部数据应来自不同采集与标注过程。三层缺一时，结论需要相应降级，而不是简单标记为“有泄漏/无泄漏”。

本项目的新患者级 test 解决第一层，在本轮开始时也相对旧方案保持新鲜；随着多个新方案被评价，第二层保护会逐渐减弱。RSNA 提供第三层差异，但又参与混合训练，混合方案的 RSNA test 不再是未知域验证。报告逐项说明这些状态，避免一个“外部验证”标签掩盖不同问题。

2.10 评价指标之间为何会冲突

设模型 A 把所有阳性排在阴性之前，但概率普遍接近 1；模型 B 排序稍差，却在 0.5 附近更平衡。A 可以有更高 AUC、更差 Brier 和更低 specificity；B 则可能在默认阈值有更高 balanced accuracy。低成本稳健 DenseNet 正体现这种冲突：RSNA 固定阈值改善，AUC 下降。

指标冲突不是评价失败，而是模型行为具有多个维度。课程报告需要先说明用途，再决定主指标。本项目没有临床成本函数，采用 balanced accuracy 作为双类操作点门槛，同时保留 AUC、Brier 和 ECE 作为否决信息。如果 balanced accuracy 提高而 AUC 明显下降，结论限定为操作点改善。

阈值选择还会改变 precision 与 recall，但不改变原始概率排序。温度缩放一般保持 AUC，却会通过 0.5 边界改变分类标签。将“校准后 accuracy 变化”解释成模型重新学到更好特征是不准确的，它只是输出映射变化。

2.11 课程设计中的负结果

负结果不是没有完成工作。一个可复核的负结果需要明确假设、唯一主要变量、相同预算、完整预测和限制解释。旧全模型微调、低成本稳健方案 AUC 下降、域均衡未

超过简单混合，都回答了具体问题。删除这些结果会产生选择性报告，使最终方案看起来比实际更确定。

本项目采用停止规则约束方法数量：简单混合达到双域门槛后，不继续使用 RSNA test 挑选更复杂方法。该规则牺牲了获得更高单次数字的机会，却提高研究解释的可信度。这也是模式识别实验设计的一部分。

第三章 数据集、任务定义与完整性审计

3.1 任务定义

本项目输入单张胸部 X 光图像，输出阴性与肺炎两类概率。Kermany 目录使用 NORMAL/PNEUMONIA 命名；RSNA 的 target=0 更准确的医学含义是“没有肺炎目标框或未标为肺炎”，不能等同于完全健康；NIH 的 No Finding/Pneumonia 来自报告文本挖掘。为保持代码接口统一，目录仍使用 NORMAL 和 PNEUMONIA，但正文按具体来源解释标签。

3.2 Kermany 儿童胸片

Kermany 数据由公开数据页和 Cell 论文描述 [5, 6]。本地逐文件检查得到 5856 张可读图像。官方目录 train 为 5216 张、val 为 16 张、test 为 624 张。训练集肺炎比例约 74.3%，test 约 62.5%。官方 val 每类只有 8 张，不能稳定承担 checkpoint、阈值或温度选择。

表 3.1: Kermany 官方目录图像统计

集合	阴性	肺炎	合计
train	1341	3875	5216
val	8	8	16
test	234	390	624
合计	1583	4273	5856

3.3 RSNA 外部数据

RSNA 挑战数据建立在 NIH 胸片基础上，并由专家补充可能肺炎标注 [11]。完整挑战集规模远大于本项目实际使用部分。本项目从可访问镜像中得到 1707 张图像，按患者 ID 固定为 train 1052、val 213、test 442。test 包含阴性 215 张、肺炎 227 张。标签 CSV 中同一患者可能有多个框，数据准备脚本先聚合 patientId，只要任一记录 Target=1 便记为肺炎，box count 另行保存。

表 3.2: RSNA 镜像可用子集统计

集合	阴性/非肺炎	肺炎	合计
train	560	492	1052
validation	107	106	213
test	215	227	442

该子集达到本项目预设的外部 test 每类至少 200 张门槛，但它不是完整挑战数据，也不是重新随机抽取的全国代表样本。RSNA train/val 已参与部分适配方案开发，因此 RSNA test 在旧项目中存在多轮观察风险。新版将其定位为主要外部压力测试，并保留这一限制。

3.4 NIH 弱标签子集

NIH ChestX-ray 数据通过报告文本挖掘产生多疾病标签 [13]。项目从一个可用压缩包中选择 65 张 No Finding 和 65 张标签含 Pneumonia 的图像，形成 92/12/26 张 train/val/test。test 每类只有 13 张。其作用是检查结论在另一弱标签来源上是否出现方向性异常，不用于模型选择，也不用于宣布外部验证成功。

3.5 审计方法

完整性审计由 scripts/audit_integrity.py 完成，包含四层检查：

1. 目录层：统计每个 split 和类别的图像数量；
2. 患者层：Kermany 按文件名提取肺炎和阴性 subject 编号；RSNA 使用 patientId；
3. 文件层：计算全部图像 SHA256，检查跨 split 完全重复与标签冲突；

4. 结果层：读取评价 JSON 指向的预测 CSV，重新计算 accuracy、precision、recall、specificity、F1、AUC、Brier 和混淆矩阵。

审计是只读的，不自动移动原始数据，也不根据模型结果改变 split。机器结果保存在 `results/integrity_audit.json`。

3.6 审计结果

40 份含预测 CSV 的评价 JSON 没有发现数值不一致；较早 JSON 缺少部分后来新增字段，属于 schema 演进。三个数据集均没有字节级相同图像跨 split，也没有相同图像标签冲突。最严重的问题出现在 Kermany 患者层：肺炎类有 170 个 subject ID 同时出现在官方 train 和 test。比如同一 `person1` 的细菌性图像在 train，而病毒性图像在 test。两者二分类标签相同，但患者解剖和采集特征并不独立。

表 3.3: 完整性审计摘要

数据集	图像数	跨 split 患者 ID	精确重复组	结论
Kermany 官方目录	5856	170	0	患者独立门禁失败
RSNA 处理后子集	1707	0	0	当前划分门禁通过
NIH 弱标签子集	130	0	0	完整性通过，样本量不足

患者交叉不等于旧准确率必然被高估。旧官方 test 的人群和子类型组成可能比重新随机分组的 test 更难。后续结果确实显示，患者级随机划分的内部准确率反而更高。因此本文只作风险判断：官方结果不能作为严格患者独立估计；不把新旧分数差异全部归因于泄漏。

3.7 患者级重划分

项目汇总官方 train/val/test 全部图像，以标签和 subject ID 为组，按 70%/10%/20% 分层分配，seed 固定为 42。同一 subject 的全部图像只进入一个集合。输出采用 hardlink 避免复制图像字节，逐图 manifest 记录新路径、标签、subject、原 split、原路径和 SHA256。

表 3.4: Kermany 患者级新划分

集合	图像数			患者标识数	
	阴性	肺炎	合计	阴性	肺炎
train	1113	2994	4107	1011	1172
validation	156	423	579	144	167
locked test	314	856	1170	289	335

manifest SHA256 以 `ef73fd9733898e62` 开头，完整值保存在划分摘要。新数据通过患者、哈希和标签三层审计。所有新版内部主结果基于此划分；旧官方结果只用于复现与敏感性讨论。

3.8 数据集差异与混杂

Kermany 主要为儿童胸片，RSNA 来自更复杂人群和不同挑战标注流程；Kermany 本地文件为 JPEG 且保留原始纵横比，RSNA 处理图为 PNG 并在预处理时统一尺寸；NIH 又使用弱标签。模型面对的变化同时包括人群、疾病定义、图像格式和灰度风格，无法用一个变量解释。

表 3.5: 三个数据来源的关键差异

项目	Kermany	RSNA 子集	NIH 子集
主要人群	儿童	更复杂，含成人	NIH 临床胸片
标签来源	目录标签	专家挑战标注及框	报告文本挖掘
项目用途	开发与内部评价	外部压力测试/适配	弱标签敏感性分析
图像格式	JPEG	DICOM 镜像转换 PNG	PNG
主要风险	原官方患者交叉	镜像非完整数据	样本极小、标签噪声

边界说明：数据集之间的性能差异同时反映模型泛化、人群差异、标签差异和图像处理差异。本文不把外部下降解释为单一算法失败，也不把 RSNA 阴性直接称为健康正常。

3.9 患者标识解析的误差边界

Kermany 没有随当前镜像提供独立患者表，患者标识由文件名推断。肺炎文件形如 `person100_bacteria_475.jpeg` 或 `person100_virus_184.jpeg`，解析器取 `person100`。阴性文件形如 `IM-0115-0001.jpeg` 或 `NORMAL2-IM-1427-0001.jpeg`，解析器取检查编号前缀。

这种规则比图像级随机划分更严格，但不是完美患者真值。后缀可能表示同一检查的多张图，也可能表示不同检查；`person` 编号跨细菌/病毒子目录时是否始终指同一真实患者，需要原始数据说明或作者元数据确认。由于重复编号至少表示高度相关的命名组，把它们放入同一 `split` 是保守选择。

新划分分别在两个二分类标签内对 `subject` 分层。这可以控制患者数比例，却不能保证图像数精确为 70/10/20，因为每个患者图像数不同。肺炎患者多图更常见，最终图像比例会有轻微偏差。表中同时报告图像数与 `subject` 数，防止把图像比例误写为患者比例。

3.10 文件哈希与感知重复

SHA256 只能发现字节完全相同文件。相同胸片若被重新压缩、缩放或改写元数据，SHA256 会不同。项目又检查了文件名 `subject` 交叉，但尚未运行大规模感知哈希或图像相似度聚类。因此“精确重复为 0”不能扩展成“没有近重复图像”。

未来可对灰度缩略图计算 `pHash`，并对高相似候选人工复核。阈值过松会把同一患者的真实随访误判为重复，阈值过严又漏掉重新压缩图。感知重复审计应作为辅助，不替代患者元数据。

`Hardlink` 构建的新数据目录与原图共享 `inode`，不增加图像字节副本。它不会让训练集和 `test` 共享路径；每个源文件只链接到一个新 `split`。若后续修改原文件，`hardlink` 内容会一起变化，因此原始数据应只读，`manifest` 哈希用于发现改变。

3.11 标签转换的具体风险

Kermany 的 `PNEUMONIA` 包含细菌和病毒文件名子型，但主任务合并二者。若细菌/病毒在官方 `train/test` 比例不同，模型难度会变化。患者级随机划分按二分类标签分层，没有额外按子型分层，可能产生子型比例波动。新版 `test` 较容易可能部分来自这一点，后续应报告子型分布。

RSNA 同一 patientId 可能有多个 box 记录。脚本先聚合，只要任一 Target 为 1 便为阳性，避免一张阳性图因重复行产生多个训练样本。Target=0 包括 “No Lung Opacity / Not Normal” 等复杂情况时，统一目录名 NORMAL 可能造成语义简化。正文因此使用 “阴性/非肺炎”。

NIH 多标签图像只要 Finding Labels 包含 Pneumonia 就进入阳性，即使同时存在 Effusion 等标签；阴性只取精确 No Finding。两类并不构成纯粹的 “肺炎唯一病变 vs 健康”，且报告挖掘标签有假阴性和假阳性。它只适合作为压力测试。

3.12 数据门禁的可维护性

完整性审计被写成独立脚本而非一次性笔记。新增数据或重新划分后可以重复执行；评价结果变化时也能检查 JSON 与 CSV 是否一致。审计返回非零退出码表示正式门禁失败，但原 Kermany 目录应持续保留 FAIL 状态，不能通过忽略患者 ID 来 “修绿”。

数据门禁还需要版本治理。manifest、summary 和审计 JSON 应进入版本控制，小型预测文件可作为核心证据；大图像和 checkpoint 由哈希与 release 管理。报告中引用绝对本机路径会降低可移植性，最终公开结果应同时提供仓库相对路径。

第四章 方法与系统设计

4.1 总体流程

项目流程分为数据层、训练层、评价层和应用层。数据层读取原始目录与标签 CSV，生成患者级 manifest，并在训练前执行完整性门禁。训练层根据配置创建模型、数据增强、损失函数、优化器和 scheduler，以 validation loss 保存 best checkpoint。评价层从 checkpoint 内嵌设置恢复模型和预处理，输出逐图概率、JSON 指标和混淆矩阵。应用层读取冻结权重，为单张上传图像提供与评价一致的推理。

这一设计强调“结果由预测文件生成”。表格中的指标不是手工录入的孤立数字，而能追溯到逐样本路径、真实标签、预测标签和两类概率。数据 manifest、配置与 checkpoint 共同决定一个 run 的含义。

4.2 图像预处理

所有模型把输入转换为 RGB 三通道并调整为 224×224 。Kermany 原图纵横比不完全一致，直接 resize 会产生形变；RSNA 处理图多为方形。当前严格基线保持原项目预处理，以便检验数据协议影响。评价阶段不使用随机增强，只执行 resize、tensor 转换和 ImageNet 归一化：

$$x'_c = \frac{x_c - \mu_c}{\sigma_c}, \quad (4.1)$$

其中 $\mu = (0.485, 0.456, 0.406)$ ， $\sigma = (0.229, 0.224, 0.225)$ 。

训练基线采用随机水平翻转和 $\pm 7^\circ$ 旋转。稳健方案增加亮度和对比度轻微扰动。胸片左右结构具有一定医学含义，水平翻转可能改变侧别标记；由于任务只做全局二分类、没有使用侧别标签，本项目把其作为基线增强保留，同时在限制中说明。大角度旋转、垂直翻转和强颜色偏移不符合胸片采集规律，未使用。

4.3 DenseNet121

DenseNet 的第 l 层接收前面所有层特征拼接：

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}]). \quad (4.2)$$

密集连接促进低层边缘与高层语义特征复用。项目使用 ImageNet 预训练 DenseNet121, 将分类器替换为两输出全连接层。严格设置为 AdamW、学习率 10^{-4} 、权重衰减 10^{-4} 、5 个 epoch 和 cosine scheduler。DenseNet 承担主基线及后续稳健/混合实验，因为其内部表现稳定、训练成本低于 ViT。

4.4 ConvNeXt-Tiny

ConvNeXt-Tiny 使用现代化卷积 stage 设计和较大卷积核，在保持卷积归纳偏置的同时吸收 Transformer 时代的训练经验。项目替换末端分类层为两类输出，使用 ImageNet 预训练、学习率 5×10^{-5} 、5 个 epoch。它的作用是检查“现代卷积结构”是否比 DenseNet 更能抵抗来源变化，而不是追求模型数量。

4.5 ViT-B/16

ViT-B/16 把 224×224 输入划分为 16×16 patch，共 196 个 patch。每个 patch 线性嵌入后加入位置编码和分类 token，通过多层自注意力编码。项目使用 ImageNet 预训练权重，替换 head 为两类输出。

审查发现，旧公开配置误写学习率 3×10^{-4} 和 batch 32，而发布 checkpoint 内嵌真实设置为学习率 5×10^{-5} 、batch 16、混合精度开启。错误配方在新划分前两 epoch 的 validation 准确率仅约 0.74 和 0.78。修正后同 seed 前两 epoch 达到约 0.89 和 0.97。正式结果仅使用修正配置；错误 run 保留日志但不进入汇总。

4.6 损失函数和优化

基线使用按训练集类别频数计算的加权交叉熵。若类别 c 有 n_c 个样本、总数为 N 、类别数为 C ，权重设为

$$w_c = \frac{N}{C n_c}. \quad (4.3)$$

稳健方案加入标签平滑 $\epsilon = 0.1$ ，目标分布从 one-hot 变为

$$\tilde{y}_c = (1 - \epsilon)y_c + \epsilon/C. \quad (4.4)$$

它可以抑制极端 logit，但也可能改变固定阈值概率，因此必须联合观察 AUC、Brier 和 ECE。

AdamW 把权重衰减与梯度更新分离。cosine scheduler 在预设 epoch 内逐步降低学习率。checkpoint 按 validation loss 最小保存，不按 test 结果选择。当前训练没有在每个 epoch 提前停止，以保证各 seed 预算一致；best checkpoint 仍可来自不同 epoch。

4.7 随机性控制

训练同时设置 Python、NumPy、CPU 和 CUDA 随机种子，关闭 cuDNN benchmark 并请求确定性算法。RTX 5080 上的 Flash/Memory-Efficient Attention 会报告部分反向算子无法完全确定，程序以 warn-only 记录。为避免把“设置了 seed”误写成“位级完全可复现”，本文把三 seed 统计作为主要稳定性证据，并保留环境和警告日志。

4.8 混合训练与域均衡

患者级 Kermany train/validation 与 RSNA 对应集合合并，文件名前加 `kermany_` 或 `rsna_` 保存来源。简单混合训练按全部图像普通 shuffle，因此样本更多的 Kermany 占更大权重。域均衡采样为来源 d 中的每个样本赋予 $1/n_d$ 权重，再有放回抽样，使两个来源期望采样概率近似相同。

域均衡只平衡来源，不同时保证来源内类别平衡；类别不均衡仍由损失权重处理。这种两层机制可能增加梯度方差，因此必须用多 seed 检查。混合训练使用同一 DenseNet 结构和 5 个 epoch，内部与 RSNA 测试分别评价。

4.9 概率校准与阈值

模型 logit 除以温度 $T > 0$ 后再 softmax：

$$p_T(y = k \mid x) = \frac{\exp(z_k/T)}{\sum_j \exp(z_j/T)}. \quad (4.5)$$

T 只能在 validation 预测上按 NLL 拟合。 $T > 1$ 通常降低极端置信, $T < 1$ 增强置信。内部 test 使用 Kermamy validation 拟合温度; RSNA test 若做目标域校准, 只能使用 RSNA validation。两种情形回答的问题不同: 前者是同来源内部校准, 后者是在目标域已有标注校准数据时的适配。

默认阈值 0.5 便于比较。若选择冻结操作点, 则在 validation 上最大化预设指标或满足召回下限后固定, 再应用 test。test 阈值扫描仅画权衡曲线, 不报告为部署最优阈值。

4.10 错误分析与 Grad-CAM

错误分析把样本划分为 FP、FN、高置信错误和概率 0.4–0.6 边界样本。FP 反映阴性误报, FN 反映肺炎漏检。高置信错误门槛预先设定, 例如错误类别概率不低于 0.9。错误网格按固定规则选取概率最极端与最接近阈值的样本, 避免只挑视觉上易解释的图。

Grad-CAM 对 DenseNet 最后特征层计算目标类别梯度并加权汇总。本文展示成功与失败案例, 解释模型使用的区域, 但不把热图当作病灶分割。RSNA 框只可用于粗粒度一致性探索。

4.11 网页演示

网页由浏览器前端和 Flask 推理接口组成。后端启动时加载 checkpoint 和类别顺序, 上传后检查文件、读取 PIL 图像、执行 checkpoint 内嵌预处理并返回 JSON 概率。页面展示 NORMAL 和 PNEUMONIA 概率、阈值、预测倾向和明确警示。网页不在线训练, 不保存患者资料, 也不允许根据上传图像修改阈值。

4.12 参数量、计算量与比较公平性

DenseNet121、ConvNeXt-Tiny 与 ViT-B/16 的参数规模和计算图不同。ViT-B/16 参数更多、batch 受 16GB 显存限制为 16; 两个 CNN 可用 batch 32。若强制完全相同 batch, 可能让 ViT 无法运行; 若各自使用合理 batch, 又不能把差异解释为纯架构因果效应。

本文采用“实用配方公平性”: 每个模型使用已验证可训练的预训练设置, epoch 接近, checkpoint 按同一 validation loss 规则选择, 每个设置运行相同 seed 数。它回答

的是课程项目中三条可实施路线的整体表现，而不是控制所有训练变量后的架构消融。

为了减少选择机会差异，未对某个模型单独进行大量 test 驱动搜索。ViT 学习率修正来自发布 checkpoint 内嵌真实记录，而不是根据新 test 挑选。DenseNet 作为后续方法主干，是在内部稳定性、训练成本和旧胸片使用经验基础上选择，不代表其 test 分数最高。

4.13 checkpoint 选择与过拟合

每个 epoch 结束后计算 validation 加权交叉熵，若低于历史最优便保存 best checkpoint，同时始终保存 last checkpoint。报告评价 best 而非 last。validation loss 同时受类别权重和概率尺度影响，可能选择 accuracy 相近但置信不同的模型。

训练只运行 4-5 个 epoch，没有长时间训练后再从大量 epoch 挑选，因此选择机会有限。曲线显示多数 CNN 在 2-5 epoch 已经接近饱和，后期 train loss 继续下降而 validation loss 波动，提示进一步训练可能过拟合。ViT 正确学习率下也在 4 epoch 内达到约 0.97 validation accuracy。

严格的后续工作可以预设 patience 并最多训练 20 epoch，但不同 run 实际 epoch 会变化。当前固定短预算更适合课程比较，也降低算力消耗。

4.14 域策略的目标函数解释

简单混合最小化所有训练图像平均损失：

$$\mathcal{L}_{mix} = \frac{1}{N_K + N_R} \left(\sum_{i \in K} \ell_i + \sum_{j \in R} \ell_j \right). \quad (4.6)$$

由于 $N_K > N_R$ ，Kermany 贡献更大。域均衡近似最小化两个域平均损失的均值：

$$\mathcal{L}_{db} = \frac{1}{2} \left(\frac{1}{N_K} \sum_{i \in K} \ell_i + \frac{1}{N_R} \sum_{j \in R} \ell_j \right). \quad (4.7)$$

实现通过 WeightedRandomSampler 近似，而不是在每个 batch 显式包含等量两域。某些 batch 仍可能不平衡，有放回抽样也会重复样本。这些实现细节解释了域均衡的随机波动。

GroupDRO 会进一步优化最大组损失，CORAL 会对齐特征协方差。它们需要明确组、对齐层与权重，并增加超参数。简单混合达到预设门槛后，本项目按停止规则没

有在同一 RSNA test 继续搜索这些方法。

第五章 实验协议与统计方法

5.1 实验环境

正式实验运行于 WSL Linux 环境，GPU 为 NVIDIA GeForce RTX 5080 Laptop GPU，显存约 16GB。代码使用 Python、PyTorch、torchvision、timm、scikit-learn、Pillow、NumPy、pandas、matplotlib 和 seaborn。依赖由 `requirements.txt` 记录，训练日志保存到 `logs/`，checkpoint 保存到 `outputs/checkpoints/`。

硬件型号影响速度和部分 CUDA 算子选择，但不应改变数据协议。所有正式结果保存 checkpoint 设置、epoch 历史、类别顺序和设备信息。公开发布时大权重通过 release 附件分发，并提供 SHA256。

5.2 数据职责

患者级 Kermany train 用于更新参数，validation 用于 best checkpoint、配方比较、阈值和温度，locked test 用于冻结后的内部评价。RSNA train/validation 只在混合和域适配实验中使用；RSNA test 用于外部压力测试。NIH test 只作补充，不参与选择。

表 5.1: 数据集合职责与允许操作

集合	参数训练	超参数/阈值选择	结果用途
Kermany grouped train	是	否	模型开发
Kermany grouped validation	否	是	checkpoint 与校准
Kermany grouped locked test	否	否	最终内部估计
RSNA train	仅适配实验	否	跨域训练
RSNA validation	否	目标域校准/混合 checkpoint	适配开发
RSNA test	否	否	外部压力测试
NIH test	否	否	弱标签敏感性

旧项目已多次查看官方 Kermany 和 RSNA test。新患者级 Kermany test 在本轮重新生成，但本报告编写期间已用于严格基线和候选方案比较，因此它仍是课程设计中的锁定评价，而不是未来论文意义上的完全不可见验证。本文如实记录这一事实。

5.3 实验矩阵

正式矩阵分四层：

1. 三模型严格基线：DenseNet121、ConvNeXt-Tiny、ViT-B/16，各 seed 42/43/44；
2. 来源诊断：简单图像统计的 Kermany/RSNA 来源分类；
3. 低成本稳健 DenseNet：强度扰动 + 标签平滑，各 3 seeds；
4. 跨域 DenseNet：简单混合与域均衡，各 3 seeds。

旧官方划分实验、随机初始化、冻结 head、最后 block 解冻和全模型 RSNA 微调保留为历史探索，不与新版患者级结果混成同一主表。这样避免不同数据协议的数字被误解为公平对照。

5.4 评价指标

混淆矩阵定义 TN、FP、FN、TP。主要指标为：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (5.1)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (5.2)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (5.3)$$

$$\text{Specificity} = \frac{TN}{TN + FP}, \quad (5.4)$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (5.5)$$

类别比例不平衡时，accuracy 可能被多数类主导，因此把 balanced accuracy 作为双域方案主要门槛。AUROC 描述跨阈值排序；AUPRC 补充阳性类 precision-recall；Brier 和 ECE 描述概率误差。报告不以“F1 最高”替代阴性误报分析。

5.5 多随机种子

每个核心设置运行 seed 42、43、44。对非线性深度模型，单次结果可能受到初始化、batch 顺序和 CUDA 算子影响。本文报告三个 seed 的均值与样本标准差，并为三 seed 概率平均集成结果计算患者级 bootstrap 区间。三 seed 数量仍有限，标准差只能描述本次运行范围，不能等同于总体方差精确估计。

5.6 患者级 bootstrap

同一患者多张图像相关，不能把每张图像视为完全独立。bootstrap 以 subject 为抽样单位：从测试患者集合有放回抽取相同数量 subject，带入这些 subject 的全部图像，计算指标；重复 2000 次，取 2.5 和 97.5 百分位作为 95% 区间。RSNA 每个 patientId 对应一张处理图，患者级与图像级抽样等价；Kermany 则明显不同。

集成概率为三 seed 对应图像肺炎概率的平均。集成结果用于稳定性总结，不替代单 seed 可部署模型。若比较两方案，应在同一 bootstrap 重采样中计算指标差，以利用配对结构。当前主文重点判断区间重叠和效果方向，不把未做多重校正的大量 p 值作为证据。

5.7 成功标准

稳健方案预先采用双域门槛：RSNA balanced accuracy 相对严格 DenseNet 基线至少提高 3 个百分点，Kermany 内部 balanced accuracy 绝对下降不超过 1 个百分点，三个 seed 方向一致。若仅固定阈值指标提高而 AUC 下降，结论为“操作点部分改善”；只有排序、固定阈值和校准共同改善，才称为全面改善。

复杂域方法的进入条件是低成本方法不足。若简单混合已经明显提高外部 AUC 和 balanced accuracy，优先保留可解释方案，不为增加工作量继续堆方法。这个停止规则避免在同一外部 test 上反复寻找偶然最高值。

5.8 完整性门禁

正式 run 前要求：患者交叉为 0、跨 split 精确重复为 0、标签冲突为 0、manifest 哈希与冻结摘要一致。run 后要求：评价 JSON 能由预测 CSV 复算、checkpoint 存在、配置记录完整。最终报告要求摘要、正文、结论和 README 数字一致。

审计脚本对原 Kermany 返回 FAIL 是预期行为，对患者级新划分返回 PASS。不能为了让所有命令“绿色”而隐藏原数据问题；机器门禁的职责是阻止错误协议被误当作正式结果。

5.9 研究解释规则

本文遵循以下解释顺序：先看数据协议是否有效，再看效应大小和不确定性，最后讨论模型机制。外部性能下降不能仅凭 AUC 推断临床失效；内部高分也不能推断临床可用。NIH 小样本不作模型排名。Grad-CAM 不作定位证明。任何事后分析在正文明确标记。

5.10 实验注册表与命名规则

正式结果文件采用方案_数据集_split_模型_seed 命名。strict 表示患者级 Kermany-only，robust 表示强度扰动加标签平滑，mixed_simple 和 mixed_domain_balanced 表示两种跨域策略。训练摘要、评价 JSON、预测 CSV 和图表使用相同后缀。

一个正式 run 至少需要：训练摘要含完整 settings 和 history；best checkpoint 存

在；validation、internal test 和 RSNA test 评价存在；预测 CSV 行数等于数据集样本数；指标复算一致。缺少任一项时不进入聚合。

错误配置 run 不会删除，以便追踪问题，但不使用正式前缀。报告在审计部分说明为什么排除。这样既不污染主结果，也不掩盖曾发生的配置问题。

5.11 比较机会与测试集治理

模型开发中最容易忽略的是“看了多少次 test”。即使每次都没有把 test 图像放进反向传播，只要研究者根据 test 分数决定下一方案，test 信息已经影响研究。旧项目多轮观察官方 Kermany 和 RSNA，新版明确把旧矩阵标为探索性。

患者级新 test 在划分生成后用于三模型、稳健和混合方案。因为用户要求本轮完成全计划，无法再另留一个完全不看的 Kermany 集合。报告因此不将其称为未来投稿意义的最终盲测。若继续研究，应冻结当前方案并创建新的外部集合，而不是继续切分同一 5856 张图。

RSNA 混合方案的 train/val 与 test 按 patientId 隔离，但研究者已经看到 Kermany-only 的 RSNA test 后才设计混合。它是合理的改进实验，却可能对 RSNA 特定问题适应。第三来源复核仍是必要条件。

5.12 bootstrap 实现细节

每次 bootstrap 从唯一 subject 列表有放回抽取与原列表等长的 subject 序列。一个 subject 被抽中两次时，其全部图像在重采样数据中重复两次；没有抽中的 subject 不出现。随后用集成概率和固定 0.5 阈值计算指标。

某次重采样若只含一个类别，AUC 无定义，应跳过；当前患者数足够，此情况极少。百分位区间没有作偏差校正，属于直观非参数区间。对于模型差异，最严格做法是在同一次抽样中计算 $M_A - M_B$ ，而不是只比较两个独立区间是否重叠。

报告目前给出各模型区间，并使用预设效果门槛做主判断。未来投稿应补充配对差值区间和多个外部 site 的分层 bootstrap。

5.13 计算预算与环境记录

正式基线共 9 次训练，稳健方案 3 次，简单混合 3 次，域均衡 3 次，共 18 次新版训练。每次生成内部和外部预测；另有 validation 评价、温度拟合、阈值冻结和错误

分析。GPU 训练串行执行，避免多个 run 争用显存造成不可控差异。

日志记录 epoch 级 train/validation loss 和 accuracy。当前没有记录能耗，不能做绿色 AI 定量比较。不同模型训练时间可以在日志时间戳估计，但未作为性能指标，因为 WSL 进程与后台负载会影响时间。

第六章 患者级内部基线与协议影响

6.1 旧官方划分复现

旧项目以 Kermany 官方 test 的 624 张图像为主要结果。ViT-B/16 默认阈值准确率 0.9006、F1 0.9248、AUC 0.9710；DenseNet121 准确率 0.9054、F1 0.9288、AUC 0.9744；ConvNeXt-Tiny 准确率 0.8878、F1 0.9171、AUC 0.9781。预测 CSV 复算与 JSON 一致，因此这些数字在计算意义上正确。

审计改变的是数字的解释。官方 train/test 有 170 个肺炎 subject ID 交叉，官方 val 又只有 16 张。旧结果应写为“在公开目录划分上的复现表现”，不能继续写成“患者独立内部性能”。此外，多模型与阈值方案都观察过同一 test，方案选择也可能适应该集合。

表 6.1: Kermany 官方目录复现结果（探索性历史基线）

模型	Acc	Precision	Recall	Spec	F1	AUC
ViT-B/16	0.9006	0.8779	0.9769	0.7735	0.9248	0.9710
DenseNet121	0.9054	0.8770	0.9872	0.7692	0.9288	0.9744
ConvNeXt-Tiny	0.8878	0.8524	0.9923	0.7137	0.9171	0.9781

三模型共同表现为肺炎召回高、阴性特异度低，说明训练类别比例和官方 test 分布使模型偏向肺炎。ConvNeXt 虽然 AUC 最高，默认阈值误报最多，体现排序与操作点不同。

6.2 患者级严格基线

在新划分上，每种模型运行三个 seed。表6.2报告单 seed 均值和样本标准差。三个模型内部 accuracy 均超过 0.975，AUC 均超过 0.992，差异小于 seed 波动和 bootstrap 不确定性。

表 6.2: 患者级 locked test 三 seed 结果 (均值 $\pm$ 标准差)

模型	Acc	BAcc	Recall	Spec	AUC
DenseNet121	0.9752 ± 0.0037	0.9713 ± 0.0050	0.9798 ± 0.0047	0.9628 ± 0.0102	0.9929 ± 0.0003
ConvNeXt-Tiny	0.9764 ± 0.0013	0.9704 ± 0.0057	0.9833 ± 0.0053	0.9575 ± 0.0163	0.9964 ± 0.0010
ViT-B/16	0.9781 ± 0.0064	0.9769 ± 0.0053	0.9794 ± 0.0078	0.9745 ± 0.0032	0.9965 ± 0.0005

ViT 均值略高, 但 accuracy 标准差也是三者最大。ConvNeXt 的 AUC 接近 ViT, specificity 波动较大。DenseNet 训练最快、内部指标接近, 因而适合作为方法消融主干。没有证据支持“ViT 显著优于 CNN”或“ConvNeXt 显著优于 DenseNet”。

6.3 三 seed 集成与置信区间

对同一图像平均三 seed 概率后, ViT 集成 accuracy 0.9821、balanced accuracy 0.9817; DenseNet 分别为 0.9803 和 0.9765; ConvNeXt 分别为 0.9778 和 0.9727。患者级 bootstrap 给出的 balanced accuracy 95% 区间为: DenseNet [0.9656,0.9865], ConvNeXt [0.9605,0.9838], ViT [0.9723,0.9898]。区间大幅重叠。

表 6.3: 三 seed 概率集成的患者级内部结果

模型	Acc	BAcc	BAcc 95% CI	F1	Brier
DenseNet121	0.9803	0.9765	[0.9656,0.9865]	0.9865	0.0175
ConvNeXt-Tiny	0.9778	0.9727	[0.9605,0.9838]	0.9848	0.0173
ViT-B/16	0.9821	0.9817	[0.9723,0.9898]	0.9877	0.0166

集成比单 seed 均值略高是常见现象, 因为不同模型错误可以部分抵消。它增加三倍推理成本, 本项目没有把集成部署到网页。表中集成仅用于稳定总结。

6.4 为什么新划分分数更高

新患者级 test 的内部 accuracy 约 0.98, 高于官方 test 约 0.90。若只关注泄漏, 容易预期去泄漏后分数下降; 实际相反说明两种划分还改变了数据分布。官方 test 的肺炎子类型、成像难度和阴性构成可能与 train 不同, 而新划分从全部数据按患者随机分层, 更接近同来源随机内部验证。

这并不说明患者交叉无关紧要。患者级独立是评价必要条件, 但评价难度同时由分布决定。本文作两点修正: 第一, 旧官方 test 保留为具有分布挑战性的公开 benchmark;

第二，新 test 只估计同来源、患者独立的随机划分性能。二者回答不同问题，不把分数差写成单一泄漏效应。

6.5 配置漂移修复的影响

ViT 错误学习率 run 提供了一个工程反例。学习率 $3e-4$ 时前两 epoch validation accuracy 为 0.7409 和 0.7789；恢复 checkpoint 真实学习率 $5e-5$ 后，对应 seed 前两 epoch 为 0.8946 和 0.9655，最终 validation 约 0.974。若不检查 checkpoint 内嵌设置，可能错误得出“ViT 在患者级划分上失效”。

因此，可复现性不只需要代码存在，还要求配置、README 命令、checkpoint 和报告一致。新版把 checkpoint 设置视为历史 run 真值，并修正公开 YAML。后续正式结果从新的训练摘要读取设置。

6.6 内部结果小结

RQ1 得到初步回答：官方目录存在患者交叉，旧结果不能作为严格患者独立估计；重新分组后，三模型在同来源未见患者上都能取得较高性能。模型间差异很小，无法支撑结构优越性强结论。更关键的问题是这些模型能否迁移到来源不同的数据。

6.7 逐 seed 结果与稳定性解释

DenseNet 三个 seed 内部 accuracy 约为 0.971、0.978 和 0.977，标准差 0.0037；ConvNeXt 集中在 0.975–0.978，标准差最低；ViT 约 0.971–0.984，标准差最高。AUC 的 seed 波动远小于 accuracy，表示排序较稳定，0.5 附近样本的标签变化造成了更多分类波动。

specificity 通常比 recall 波动大。原因之一是 locked test 有 314 张阴性和 856 张肺炎，阴性样本更少；一个阴性错误对 specificity 的影响约为 $1/314$ ，一个肺炎错误对 recall 影响约为 $1/856$ 。因此不能仅凭 specificity 标准差较大断言模型对阴性“训练不稳定”，样本分母也影响波动尺度。

ViT 集成 balanced accuracy 最高，但相对 DenseNet 集成只高约 0.0052，远小于两个区间宽度。若以此选择网页模型，会增加约 1GB 权重与更高推理成本，收益证据不足。DenseNet 后续作为研究主干是精度、稳定性和成本的折中。

6.8 类别比例与 accuracy 解释

新 locked test 肺炎占 856/1170, 约 73.2%, 接近训练比例。一个总判肺炎的无信息分类器也能获得约 0.732 accuracy, 因此 0.98 准确率虽高, 仍应和 balanced accuracy 0.97 一起报告。官方 test 肺炎占 62.5%, 类别构成不同也会改变 accuracy。

precision 同样依赖阳性率。新内部 test 的高 precision 不能直接与 RSNA precision 比较, 除非考虑不同阳性率和标签定义。AUC 相对不受单一阈值和类别比例直接影响, 但会受病例谱和标签噪声影响。

6.9 错误数量的实际含义

以严格 DenseNet seed42 为例, 1170 张 test 中有 13 个 FP 和 21 个 FN。表面看总错误仅 34 张, 但其中同一 subject 可能有多张图像; 患者层错误数可能低于图像层, 也可能一个患者多次错误。正式医学评价应按患者聚合或预先指定 index exam, 当前图像级任务仍以逐图指标为主, bootstrap 按患者修正不确定性。

高置信错误有 5 个 FP 和 6 个 FN。即使内部 AUC 接近 0.993, 也存在远离阈值的错误, 说明不能用阈值微调消除全部问题。错误可能来自标签噪声、非典型表现或模型捷径, 需要医学复核才能进一步分类。

第七章 外部泛化与数据域差异

7.1 直接迁移设置

三模型仅在 Kermany 患者级 train 训练、按 Kermany validation 选 checkpoint, 然后不作 RSNA 适配, 直接评价 442 张 RSNA test。该设计测量从儿童公开胸片到不同来源挑战数据的迁移。默认阈值仍为 0.5, 不在 RSNA test 调节。

7.2 RSNA 三模型结果

三个 seed 均显示明显下降。DenseNet 内部 accuracy 均值 0.9752, RSNA 降到 0.6614; ConvNeXt 从 0.9764 降到 0.6840; ViT 从 0.9781 降到 0.6599。外部下降约 29-32 个百分点, 远大于内部模型差异。

表 7.1: Kermany 训练模型在 RSNA test 上的三 seed 结果

模型	Acc	BAcc	Precision	Recall	Spec	AUC
DenseNet121	0.6614 ± 0.0125	0.6530 ± 0.0130	0.6078 ± 0.0100	0.9618 ± 0.0092	0.3442 ± 0.0326	0.8078 ± 0.0151
ConvNeXt-Tiny	0.6840 ± 0.0026	0.6777 ± 0.0022	0.6337 ± 0.0014	0.9119 ± 0.0192	0.4434 ± 0.0150	0.8015 ± 0.0145
ViT-B/16	0.6599 ± 0.0220	0.6518 ± 0.0224	0.6083 ± 0.0161	0.9501 ± 0.0167	0.3535 ± 0.0426	0.8171 ± 0.0097

主要错误不是肺炎完全无法识别, 而是阴性样本大量被判为肺炎。DenseNet recall 约 0.96、specificity 约 0.34; ViT 相似; ConvNeXt 牺牲部分 recall 换取约 0.44 specificity。AUC 仍约 0.80, 说明概率排序保留一定信息, 但 0.5 操作点严重偏向阳性。

7.3 外部集成与不确定性

三 seed 集成的 RSNA balanced accuracy 为 DenseNet 0.6591、ConvNeXt 0.6695、ViT 0.6594。患者 bootstrap 95% 区间分别为 $[0.6246, 0.6941]$ 、 $[0.6312, 0.7053]$ 和 $[0.6247, 0.6935]$, 高度重叠。AUC 集成分别为 0.8152、0.8040 和 0.8236。

这些数字不支持明确模型排名。ViT AUC 略高但固定阈值不优；ConvNeXt balanced accuracy 略高但区间重叠。更稳妥的结论是：三种结构都受到相似域偏移，结构替换没有解决问题。

7.4 来源分类诊断

项目从两个数据源各确定性抽样 1500 张图像，提取灰度均值、标准差、10/50/90 分位数、边缘均值和方差、中心均值和方差、熵等简单特征。纵横比虽然差异明显，但模型输入最终被 resize 为方形，因此来源分类器特意排除纵横比，避免用文件几何直接区分。

Random Forest 采用 5 折 StratifiedGroupKFold，患者组不跨训练和验证。最终 overall accuracy 为 0.8880，AUC 为 0.9551。各折 AUC 接近，说明仅靠简单像素统计就能识别大部分来源。

表 7.2: Kermany 与 RSNA 简单图像统计均值

特征	Kermany	RSNA
全图灰度均值	0.4832	0.5033
全图灰度标准差	0.2227	0.2316
10% 分位数	0.1226	0.1674
90% 分位数	0.7396	0.7986
边缘均值	0.3304	0.3941
中心均值	0.5790	0.5295
中心标准差	0.1393	0.1779
灰度熵	3.0517	3.1390

来源分类结果不是肺炎模型错误的因果证明。它说明数据域在简单统计上并不相同，为外部下降提供背景。模型的 resize 会消除文件纵横比数值，却会把不同纵横比原图以不同程度拉伸，几何风格仍可能进入像素。

7.5 概率与错误结构变化

内部 test 上三模型 Brier 约 0.019；RSNA 直接迁移后，DenseNet 均值约 0.297、ConvNeXt 约 0.265、ViT 约 0.292。外部概率误差远高于内部。大量 RSNA 阴性图像获

得高肺炎概率，导致 specificity 下降。单纯升高阈值可以减少误报，但阈值若从 RSNA test 扫描得到，会产生乐观偏差。

错误网格显示两来源在裁剪、灰度范围和边缘背景上存在差异，但肉眼观察不能区分哪些差异被模型实际利用。Grad-CAM 在部分 RSNA 样本关注胸腔内部，也有样本关注较大边缘或弥散区域。热图只能作为生成机制假设，不能替代控制实验。

7.6 NIH 弱标签敏感性分析

旧项目对 26 张 NIH test 报告 ViT accuracy 0.5000、DenseNet 0.5385、ConvNeXt 0.4615。每类只有 13 张，单个样本就改变 accuracy 约 3.85 个百分点；模型间差异小于一到两个样本，因此不能排名。弱标签还可能把未在报告中提及的异常当作阴性，或包含与肺炎共存的其他标签。

NIH 结果只支持一个低强度判断：跨到第三来源时没有观察到稳定高性能。它不提供精确外部效应估计，也不能验证新混合方案。若要用于主结论，需要扩大样本并按患者、体位和标签共病重新设计。

7.7 外部结果小结

RQ3 得到明确回答：在患者级内部性能接近 0.98 的情况下，三模型 RSNA 准确率均约 0.66–0.68，specificity 尤其低。简单像素统计能够高 AUC 地区分来源。数据域差异比模型结构差异更大，后续改进应针对输入风格、训练数据覆盖和操作点，而不是继续增加网络种类。

7.8 内部到外部的指标变化

DenseNet balanced accuracy 从 0.9713 降至 0.6530，绝对下降 0.3183；ConvNeXt 从 0.9704 降至 0.6777，下降 0.2927；ViT 从 0.9769 降至 0.6518，下降 0.3251。三者下降量接近，说明没有一种结构明显抵抗该域变化。

AUC 下降相对较小但仍明显：DenseNet 约下降 0.185、ConvNeXt 下降 0.195、ViT 下降 0.179。外部 AUC 仍高于 0.8 意味着分数含有信号，固定阈值错误又非常严重，因此概率尺度漂移是主要成分之一。后续高温度校准和高阈值操作点验证了这一点。

外部 Brier 约 0.26–0.30，接近无信息 0.5 概率在平衡二分类上的 0.25 水平，且 DenseNet/ViT 更差。模型虽然 AUC 有 0.8，却因极端错误概率产生很差 Brier。判别

和校准必须同时检查。

7.9 来源分类器的五折结果

排除纵横比后，五折来源分类 accuracy 约在 0.86–0.91 范围，AUC 均保持较高，overall AUC 为 0.9551。Random Forest 输入不包含肺炎标签，只判断 Kermany 或 RSNA。患者组隔离减少同一患者多图对交叉验证的乐观影响。

特征均值显示 RSNA 边缘更亮、中心均值更低、中心方差更高。由于每张图最终 resize，模型可能看到拉伸后的边缘/中心模式。来源分类器没有告诉我们哪项特征最有因果作用，Random Forest importance 也可能偏向连续变量；本报告只把它作为“域差异可测”的证据。

更强诊断可以训练深度来源分类器，再用肺野 mask 和去边框版本比较。如果去除非肺区域后来源 AUC 明显下降，可提示边缘捷径；若仍很高，差异可能来自肺野纹理、人群或设备。当前未完成肺野分割，因此不作这一结论。

7.10 标签偏移与协变量偏移

域偏移可以粗分为输入分布变化、类别先验变化和给定图像后的标签机制变化。Kermany 与 RSNA 不仅像素风格不同，阳性定义也不同，属于多种偏移叠加。简单阈值主要处理先验和概率尺度，无法修复标签构念差异。

RSNA 阴性中可能包含非肺炎异常。Kermany NORMAL 更接近健康阴性。模型若把异常胸片普遍判为肺炎，会在 RSNA 产生 FP，但从“异常检测”角度未必完全无意义。由于项目目标明确为肺炎二分类，这些仍按 FP 统计，不能事后改变任务为“异常筛查”来解释错误。

7.11 为什么 NIH 不能补足第三外部验证

26 张 test 的二项比例区间非常宽。例如 accuracy 0.5385 对应 14/26，变化一个样本即为 0.0385。模型间 0.04–0.08 差异只有一到两个样本，不具稳定性。标签还由文本挖掘产生，疾病共现未控制。

若扩大 NIH，应先按 patient ID 划分，固定 No Finding 与 Pneumonia 规则，决定是否排除多标签阳性，并报告 PA/AP 体位与年龄。直接增加图片数而不解决标签构念，仍不能成为公平验证。

第八章 稳健训练与跨域策略实验

8.1 实验目的

直接迁移结果表明，主要问题是 RSNA 阴性误报和概率漂移。本章不再比较新架构，而围绕 DenseNet121 改变训练数据与正则化。所有方案使用患者级 Kermany 协议、相同模型和三个 seed，并同时评价内部 locked test 与 RSNA test。成功标准为外部 balanced accuracy 提高至少 0.03 且内部下降不超过 0.01。

8.2 低成本稳健训练

稳健方案相对严格 DenseNet 只增加两项：训练时启用轻度 brightness/contrast 扰动；交叉熵使用 0.1 标签平滑。其 Kermany 内部 balanced accuracy 均值 0.9742，与严格基线 0.9713 相近；RSNA balanced accuracy 由 0.6530 提高到 0.7116，三个 seed 方向一致。

表 8.1: 严格基线与低成本稳健训练三 seed 比较

方案	测试集	Acc	BAcc	Recall	Spec	AUC
严格 DenseNet	Kermany	0.9752	0.9713	0.9798	0.9628	0.9929
稳健 DenseNet	Kermany	0.9735	0.9742	0.9727	0.9756	0.9939
严格 DenseNet	RSNA	0.6614	0.6530	0.9618	0.3442	0.8078
稳健 DenseNet	RSNA	0.7164	0.7116	0.8899	0.5333	0.7826

外部 specificity 从 0.344 提高到 0.533，recall 从 0.962 降到 0.890。这不是所有方向共同改善，而是减少肺炎偏置、重新平衡误报漏检。更关键的是 AUC 从 0.8078 下降到 0.7826：概率排序能力没有改善。Brier 由约 0.297 降到 0.197，说明软化置信有利于概率误差。根据预设解释规则，该方案是固定阈值和校准意义上的部分成功。

8.3 简单混合训练

简单混合把 Kermany grouped train 与 RSNA train 合并，validation 也合并，但普通 shuffle 使 Kermany 图像仍占多数。它直接让模型观察目标域图像和标签，因此不再属于“零样本外部泛化”，而是有监督多域训练。

简单混合的 Kermany balanced accuracy 为 0.9684 ± 0.0040 ，相对严格基线下降 0.0029；RSNA balanced accuracy 提高到 0.7645 ± 0.0095 ，AUC 提高到 0.8565 ± 0.0026 。外部 accuracy、specificity 和 Brier 均改善，且内部下降未超过 1 个百分点，满足双域门槛。

表 8.2: 简单混合训练三 seed 结果 (均值 $\pm$ 标准差)

指标	Kermany locked test	RSNA test
Accuracy	0.9681 ± 0.0044	0.7632 ± 0.0107
Balanced accuracy	0.9684 ± 0.0040	0.7645 ± 0.0095
Precision	0.9885 ± 0.0018	0.8041 ± 0.0246
Recall	0.9677 ± 0.0053	0.7151 ± 0.0592
Specificity	0.9692 ± 0.0049	0.8140 ± 0.0426
F1	0.9780 ± 0.0031	0.7554 ± 0.0240
ROC-AUC	0.9943 ± 0.0012	0.8565 ± 0.0026
Brier	0.0250 ± 0.0035	0.1673 ± 0.0068
ECE	0.0101 ± 0.0004	0.0900 ± 0.0058

与稳健方案相比，简单混合的 RSNA AUC 更高，balanced accuracy 也更高。其 recall 较低、specificity 较高，说明模型不再普遍把外部阴性推向肺炎，但可能增加肺炎漏检。若应用关注高敏感度，需要在 RSNA validation 冻结较低阈值，而不能只采用 0.5。

8.4 域均衡采样

域均衡采样使 Kermany 和 RSNA 来源在每个 epoch 期望贡献相近。结果并未优于简单混合。RSNA balanced accuracy 为 0.7534 ± 0.0210 、AUC 0.8493 ± 0.0102 ；Kermany balanced accuracy 降到 0.9535 ± 0.0169 ，specificity 标准差达到 0.0488。它的跨 seed 波动更大，且内部下降约 1.8 个百分点，未通过预设双域门槛。

表 8.3: 域均衡训练三 seed 结果

指标	Kermany locked test	RSNA test
Accuracy	0.9624 ± 0.0023	0.7526 ± 0.0217
Balanced accuracy	0.9535 ± 0.0169	0.7534 ± 0.0210
Recall	0.9727 ± 0.0151	0.7239 ± 0.0487
Specificity	0.9342 ± 0.0488	0.7829 ± 0.0071
F1	0.9743 ± 0.0012	0.7498 ± 0.0289
ROC-AUC	0.9903 ± 0.0031	0.8493 ± 0.0102
Brier	0.0307 ± 0.0041	0.1670 ± 0.0120

可能原因是 RSNA 在混合集合中的样本虽少，但普通 shuffle 已经提供足够目标域覆盖；强制来源等权放大了 RSNA 小样本和标签差异，也增加有放回采样重复。该解释是基于结果的合理推测，不是因果证明。

8.5 与旧适配实验的关系

旧项目在官方 Kermany 目录上还比较 RSNA-only、冻结 head、最后 block 解冻和全模型微调。这些结果一致显示双域权衡，却使用包含患者交叉风险的官方 Kermany 训练/测试协议，且只有单 seed。新版不删除它们，但不把其与新主表直接合并。

旧简单混合 RSNA accuracy 约 0.760，和新版 0.763 接近；新版价值在于患者级内部评价、三 seed 稳定性和完整概率指标，而不只是多得到一个相似分数。旧 domain-balanced 在 RSNA recall 较低，新版也观察到该策略不稳定，方向具有一定一致性。

8.6 为何不继续堆叠复杂域方法

提升计划把 GroupDRO 和 CORAL 设为低成本方法不足时的候选。简单混合已经满足预设双域门槛，并同时提高外部 AUC、balanced accuracy 和 Brier。继续根据同一 RSNA test 选择更复杂方法，会增加测试集适应和解释成本。因此本轮按停止规则不把 GroupDRO/CORAL 投入正式主结果。

这不是“方法无法实现”，而是研究治理决策：在课程设计算力和外部数据有限时，优先保留可解释且稳定的方案。CORAL 仍列为后续工作，真正评价应增加未参与选择的第三个足量外部集合。

8.7 本章结论

RQ4 的答案是有条件的。轻度强度扰动和标签平滑改善 RSNA 固定阈值表现，却损害 AUC，只算部分改善。简单有监督混合训练取得最完整的双域收益：外部 balanced accuracy 约提高 0.11，AUC 约提高 0.05，内部下降小于 0.01。域均衡没有超过简单混合且波动更大。结果支持“增加目标域覆盖比更换架构有效”，但不支持对全新医院的零样本泛化承诺。

8.8 三种策略的效果分解

相对严格 DenseNet，稳健方案 RSNA specificity 增加约 0.189、recall 下降约 0.072；简单混合 specificity 增加约 0.470、recall 下降约 0.247；域均衡 specificity 增加约 0.439、recall 下降约 0.238。三个方案都在纠正原模型过度预测肺炎，只是程度不同。

简单混合 AUC 增加约 0.049，说明不仅阈值移动，排序也改善。稳健方案 AUC 下降约 0.025，主要是输出尺度和边界变化。域均衡 AUC 增加约 0.042，但低于简单混合且方差更大。Brier 方面，简单混合和域均衡均约 0.167，稳健约 0.197，三者都优于严格基线 0.297。

内部代价不同：稳健内部 accuracy 只下降约 0.002；简单混合下降约 0.007；域均衡下降约 0.013 且 balanced accuracy 下降约 0.018。根据预设 1 个百分点门槛，前两者通过，域均衡失败。

8.9 验证集表现与 test 一致性

简单混合在 RSNA validation 三个 seed accuracy 约 0.75–0.82，test 约 0.75–0.78，方向接近但波动存在。validation AUC 约 0.858–0.889，test AUC 稳定约 0.853–0.859。AUC 的 validation-test 差异小于固定阈值 accuracy 差异，支持概率排序相对稳定、操作点受样本影响更大。

域均衡 validation 用于混合数据 checkpoint 选择，不是纯 RSNA 指标。一个 checkpoint 可能因 Kermany 部分 validation 改善而被保存，即使 RSNA 部分不最佳。未来可预设双域 validation 目标，例如两个域 balanced accuracy 的调和平均，但这会新增选择指标，需要新的外部 test 验证。

8.10 有监督适配的实际含义

简单混合需要 RSNA train 的 1052 张有标签图像。这一前提在新医院可能昂贵，但比完整重新训练成本低。若只有未标注目标图像，简单混合不可用，需要无监督域适配或自监督预训练。若只有少量标签，则应画学习曲线，比较每类 10、50、100、500 张的收益。

当前没有做样本量学习曲线，因此不知道收益来自少量目标样本还是必须使用全部 1052 张。课程结论只说明“当前规模目标域监督有效”。未来学习曲线比再换一个模型更有实践价值。

8.11 失败方案的保留规则

域均衡结果进入主文，是因为它对应清楚假设且完成三个 seed。低成本方案 AUC 下降也保留。旧冻结 head、last block 和 full fine-tune 则放在历史讨论，因为数据协议不同，不能和新版做数值排名。

报告方案时使用完整矩阵，不只选择 seed43 域均衡 RSNA accuracy 0.7760 这样的最好单次。seed44 只有 0.7330，三 seed 均值 0.7526 才代表该设置。选择性报告单次最好值会掩盖策略不稳定。

第九章 概率可靠性、阈值与错误解释

9.1 同来源内部校准

严格 DenseNet 在 Kermany 内部 test 本身已经较好校准。三个 seed 未校准 ECE 均值 0.0081、Brier 0.0198、NLL 0.0822。使用 579 张 Kermany validation 拟合温度后，平均温度 1.067，ECE 0.0071、Brier 0.0198、NLL 0.0809，变化很小。温度接近 1 说明不需要大幅软化或锐化概率。

简单混合模型内部未校准 ECE 0.0101、Brier 0.0250；温度均值 1.17 后 ECE 0.0065、Brier 0.0249。混合训练略损害内部 Brier，但仍处于较低水平。校准没有修复判别错误，只调整概率尺度。

表 9.1: DenseNet 内部概率校准（三 seed 均值）

方案	状态	Temperature	ECE	Brier	NLL
Kermany-only	未校准	1.000	0.0081	0.0198	0.0822
Kermany-only	val 校准	1.067	0.0071	0.0198	0.0809
简单混合	未校准	1.000	0.0101	0.0250	0.0931
简单混合	val 校准	1.170	0.0065	0.0249	0.0911

9.2 RSNA 目标域校准

Kermany-only 模型直接迁移 RSNA 后平均 ECE 0.2762、Brier 0.2970、NLL 1.4503。目标域 validation 拟合的温度为 6.03、7.44 和 6.95，平均 6.807，说明原概率极度尖锐。温度缩放后 ECE 降到 0.0489、Brier 0.2143、NLL 0.6174。

初次审查时温度搜索上限为 5，三个 seed 都撞到边界。如果直接报告 $T=5$ ，会把搜索截断误当成最优值。脚本已增加可配置范围和边界标记，扩到 20 后得到内部最优且不在边界的结果。这一修正说明数值优化范围也是可复现协议的一部分。

简单混合模型 RSNA 未校准 ECE 0.0900、Brier 0.1673、NLL 0.5330，明显优于 Kermany-only；目标域温度均值 1.56 后，ECE 0.0369、Brier 0.1590、NLL 0.4830。混合训练不仅改善分类，还减轻了外部过度自信。

表 9.2: RSNA 目标域校准 (三 seed 均值)

方案	状态	Temperature	ECE	Brier	NLL
Kermany-only	未校准	1.000	0.2762	0.2970	1.4503
Kermany-only	RSNA val 校准	6.807	0.0489	0.2143	0.6174
简单混合	未校准	1.000	0.0900	0.1673	0.5330
简单混合	RSNA val 校准	1.560	0.0369	0.1590	0.4830

目标域校准假设已经获得一批有标签 RSNA validation 数据。它不属于完全无目标数据的零样本泛化。温度降低概率误差，但不改变 AUC 排序；分类标签是否变化取决于使用校准后概率仍以 0.5 判定。

9.3 validation 冻结阈值

Kermany-only 模型在 RSNA validation 最大化 balanced accuracy 时选择阈值 0.976–0.993，远高于 0.5。应用到 RSNA test 后，三个 seed balanced accuracy 为 0.7069、0.7310 和 0.7437，相比默认阈值均有改善。高阈值抵消了来源迁移造成的肺炎概率整体偏高。

简单混合模型在 RSNA validation 选择的阈值为 0.247–0.378，低于 0.5；应用 test 后 balanced accuracy 为 0.7768、0.7819 和 0.7726。混合模型的 0.5 阈值 specificity 较高、recall 较低，降低阈值恢复 recall 并获得更平衡操作点。

表 9.3: RSNA validation 选择 balanced accuracy 阈值后的 test 结果

方案/seed	阈值	Test BAcc	Recall	Specificity
Kermany-only/42	0.989	0.7069	0.6696	0.7442
Kermany-only/43	0.993	0.7310	0.8062	0.6558
Kermany-only/44	0.976	0.7437	0.8502	0.6372
简单混合/42	0.287	0.7768	0.8326	0.7209
简单混合/43	0.247	0.7819	0.8150	0.7488
简单混合/44	0.378	0.7726	0.8150	0.7302

阈值跨 seed 变化仍较大，说明 213 张 validation 不足以给出唯一稳定阈值。实际系统应根据任务成本预先确定敏感度下限，并报告相应 specificity，而不是追求一个抽象最优点。

9.4 错误样本结构

以 seed42 为代表，严格 DenseNet 在 Kermany patient-level test 有 13 个 FP、21 个 FN，其中 5 个高置信 FP、6 个高置信 FN；简单混合有 10 个 FP、23 个 FN，内部错误结构接近。

RSNA 差异更明显。Kermany-only seed42 在默认阈值产生 149 个 FP 和 7 个 FN，其中 102 个是高置信 FP；简单混合降为 42 个 FP，但 FN 增至 59 个，高置信 FP 11 个、高置信 FN 18 个。这与混淆矩阵指标一致：简单混合把模型从“几乎都判肺炎”拉回较平衡状态，却增加漏检。

表 9.4: 代表性 seed42 错误结构

方案	数据集	FP	FN	高置信 FP	高置信 FN	边界样本
Kermany-only	Kermany	13	21	5	6	13
简单混合	Kermany	10	23	6	7	9
Kermany-only	RSNA	149	7	102	0	22
简单混合	RSNA	42	59	11	18	40

高置信错误尤其重要。它们不能靠小幅移动阈值完全解决，也提示 softmax 概率不是医学确定性。网页因此必须显示课程演示警示，而不能把 99% 概率写成 99% 诊断把握。

9.5 Grad-CAM 解释

项目已有 DenseNet 在 Kermany 错误样本、RSNA 阳性和 NIH 阳性上的 Grad-CAM。部分热区位于胸腔内部，部分在边缘或较大弥散区域。新版错误网格固定展示 16 例，并由概率规则选择，减少挑图偏差。

热图不应被逐张主观解释成具体病变。没有放射科医生复核时，无法确认模型关注区是否对应浸润。RSNA 虽有框，框代表可能肺炎区域且并非精确分割；本轮没有把 box overlap 作为主要定量结果。报告只用 Grad-CAM 回答“模型是否明显依赖非

胸腔区域”的诊断性问题。

9.6 本章结论

内部高性能模型可以在外部域严重失准。目标域温度缩放显著降低概率误差，validation 阈值也能改善固定操作点，但都需要目标域标注数据。简单混合从训练阶段减少概率漂移，校准温度更接近 1，表现优于只在输出端修补 Kermany-only 模型。

9.7 温度参数的逐 seed 稳定性

严格 Kermany-only 的 RSNA 温度为 6.03、7.44 和 6.95，范围相对均值不小，但均明确大于 1。简单混合温度为 1.57、1.59 和 1.52，更集中。两个方案的差异远大于各自 seed 波动，支持“混合训练减轻外部过度自信”的判断。

Kermany 内部温度约 0.99–1.11，说明同来源概率无需大修。若把 RSNA 温度直接应用 Kermany，会过度软化内部概率。温度参数是域相关的，不能用一个全局 T 处理所有来源，除非训练和 validation 覆盖预期部署混合分布。

温度搜索以 0.01 步长进行。对结论而言，6.95 与 6.96 差异没有实际意义；报告保留两位小数即可。更重要的是验证来源、搜索边界和校准前后 NLL。

9.8 ECE 的解释限制

ECE 使用 10 个置信度箱。不同模型的样本落箱方式不同，ECE 不是严格 proper scoring rule；一个模型可通过概率集中改善 ECE，却不一定改善所有概率质量。Brier 和 NLL 提供补充，其中 NLL 对高置信错误惩罚尤其大。

严格外部模型有大量高置信 FP，NLL 1.45 明显恶化；温度后降到 0.617。简单混合未校准 NLL 0.533，温度后 0.483。即使校准后，外部 NLL 仍显著高于内部约 0.08–0.09，说明校准不能消除判别和标签差异。

9.9 阈值跨 seed 变化的来源

Kermany-only RSNA 最优阈值都接近 1，但在 0.976–0.993 之间的数值差对极端概率模型可能覆盖很多样本。简单混合阈值 0.247–0.378 跨度更明显。validation 只有 213 张，每移动几个边界样本就可能改变最优点。

因此报告不推荐单一通用阈值。更合理的是预先定义召回下限，例如 validation recall 至少 0.90, 再在可行阈值中最大化 specificity。阈值仍需在目标人群独立 validation 上估计，并报告 bootstrap 区间或敏感性范围。

9.10 错误案例如何避免挑选偏差

错误分析脚本导出所有 FP/FN 及其概率，网格只显示固定上限 16 张。排序规则和高置信门槛由代码统一，不根据热图是否“好看”选择。正文报告总数，图片只是示例。

医学人员若参与复核，应先盲于模型类型和置信度，按预设表记录图像质量、体位、明显异常和标签可疑性。复核意见不能直接改 test 标签后重新报告同一分数；应形成纠错集或敏感性分析，并保留原结果。

第十章 演示系统与软件质量验证

10.1 系统目标与边界

演示系统的目的，是让课程验收者看到训练结果如何进入单图推理，不是提供临床服务。输入为常见图片文件，输出为两类概率、预测倾向和警示。系统不接入医院信息系统，不处理 DICOM 元数据，不保存个人身份信息，也不提供治疗建议。

10.2 系统结构

前端负责文件选择、预览、请求和结果展示；Flask 后端负责模型加载、图像解析、预处理和推理。启动命令显式指定 checkpoint 与 device。后端创建 predictor 时读取 checkpoint 的 model name、classes 和 settings，避免网页硬编码与训练配置漂移。

请求流程为：用户选择文件；浏览器以 multipart/form-data 上传；后端检查文件字段；PIL 解码并转换 RGB；执行 Resize、ToTensor 和 Normalize；模型前向输出 softmax；返回 JSON。页面把 PNEUMONIA 概率与阈值比较，但同时展示 NORMAL 概率，避免只显示单个结论。

10.3 模型与权重

公开主 ViT 权重大小约 1.03GB，SHA256 以 78604698f504d8d9 开头，完整值见复现附录。大文件不直接放入普通 Git 历史，而通过 release 附件提供。README 说明下载位置和哈希检查。

新版严格实验生成多个 checkpoint，不全部作为网页默认模型发布。最终演示模型应在报告冻结后选择，并把对应数据协议、seed、阈值和权重哈希写入 release manifest。若仍使用旧 ViT 网页，仅能展示旧官方基线，页面不得暗示它等于新版最佳模型。

10.4 异常处理

接口对缺失文件返回 400 状态和结构化错误；无法解码图片时不进入模型；device=auto 优先 CUDA、不可用则 CPU。用户上传的任意图片都可能被模型强制分类，因此页面必须提示“仅适用于胸片课程演示”。系统不应根据扩展名直接信任内容，也不应把异常堆栈返回浏览器。

10.5 自动测试

原项目有阈值、校准、数据工具和网页接口测试。审计后新增患者 ID 解析与跨 split 检测测试，并增加温度搜索范围测试。当前测试共 17 项（以最终 pytest 输出为准）。网页测试使用 fake predictor，不需要加载 1GB 权重，验证上传成功、JSON 字段和缺失文件错误。

单元测试通过不代表端到端模型完全复现。最终还需运行真实 checkpoint CPU smoke test、数据审计、评价复算和 PDF 编译。软件验收按分层证据完成，而不是用一个“测试通过”概括所有质量。

10.6 复现入口

README 提供环境安装、数据目录、权重下载、网页启动和主评价命令。严格研究流程还需要：生成患者级 Kermany 划分、运行审计、按 seed 训练、评价 Kermany/RSNA、聚合 bootstrap、校准与阈值。完整命令放在附录，结果文件由 artifact index 定位。

10.7 软件边界

网页使用默认阈值时可能在 RSNA 等外部来源上产生大量误报。即使切换简单混合模型，训练数据覆盖仍有限。系统没有输入域检测、质量控制、病人年龄核验或不确定性拒识。出于这些缺失，系统只能作为“算法流程可运行”的课程证据，不能作为医疗产品原型宣传。

第十一章 综合讨论与有效性威胁

11.1 患者级审计改变了什么

最直接的改变是证据等级。旧 Kermayn 指标在数学上可复算，却不满足患者独立性；新版把它降为官方目录复现，并建立新 manifest。这个过程说明“bug”不只指代码异常，也包括数据单位与研究问题不一致。若目标是对未见患者分类，患者必须是划分单位。

审计没有支持一个简单故事：去除患者交叉后分数并未下降，反而升到约 0.98。原因是新划分同时改变了 test 分布。官方 test 可能包含更强来源/子类型偏移，新随机患者划分更接近同来源训练数据。因此患者泄漏风险与数据集难度必须分开；本文不声称 170 个交叉患者导致旧分数虚高多少。

11.2 模型结构与数据覆盖

三模型内部差异不足 1 个百分点，外部 RSNA 下降约 30 个百分点。来源分类器在排除纵横比后仍有 0.9551 AUC。两项证据共同说明，当前瓶颈主要是数据域，而不是 CNN 或 Transformer 结构。

简单混合训练把 RSNA AUC 提高到约 0.8565、balanced accuracy 提高到 0.7645，同时内部 balanced accuracy 保持 0.9684。它的收益来自目标域有监督数据覆盖，不能推广为对任意新医院的域泛化。若再到第三个未见来源，仍可能下降。真正的域泛化应在开发时不使用最终目标域标签，并在多个外部机构验证。

11.3 低成本稳健方案的双面结果

标签平滑与强度扰动减少外部过度自信，Brier 和 specificity 改善，但 AUC 下降。若只看 accuracy 或 balanced accuracy，会把它写成成功；若只看 AUC，又会完全否定它。更准确的理解是：它改变了概率尺度和 0.5 操作点，使误报减少，但排序能力没有

增强。

这一结果说明评价指标必须对应使用目的。筛查任务可能重视高 recall 下 specificity；概率风险沟通重视校准；排序或后续阈值选择重视 AUC。课程设计没有临床成本函数，因此不选唯一“最佳”指标，而报告完整权衡。

11.4 域均衡为何未胜出

域均衡让 RSNA 小来源在采样中被放大，理论上可以防止 Kermany 主导。但有放回抽样重复少量 RSNA 图像，且两个域标签语义并不完全一致。结果表现为更大 seed 波动、内部 specificity 不稳、外部不如简单混合。

不能据此断言域均衡普遍无效。当前实现只按来源平衡，不按来源-类别联合组；训练 epoch 固定，超参数也未针对该策略调节。结论限于本项目设置：在同预算和当前数据量下，没有证据支持它优于简单混合。

11.5 内部有效性威胁

第一，Kermany subject ID 来自文件名规则，不是官方患者表。规则与公开命名高度一致，但仍可能把不同患者错误合并或把同一患者拆开。第二，Flash Attention 提示非确定位算法，三 seed 缓解但没有达到位级复现。第三，模型学习率和 epoch 按架构设置，不是完全相同超参数；比较回答“合理配方下模型表现”，不是纯架构因果效应。第四，新 locked test 在本轮已被多个方案评价，后续继续迭代会使其逐渐失去锁定性。

11.6 构念有效性威胁

三个数据集的“肺炎/阴性”并非相同构念。Kermany 目录标签来自儿童病例分类；RSNA target 围绕可能肺炎框；NIH 为报告挖掘。RSNA 阴性可能包含其他异常，NIH Pneumonia 可能与其他标签共存。把它们统一成二分类便于代码，却可能把标签差异误当作视觉域偏移。

resize 到正方形会拉伸不同纵横比图像。ImageNet 三通道归一化用于复制预训练输入，却不一定是胸片最优。水平翻转可能改变侧别。未来应比较保持纵横比 padding、DICOM 窗宽窗位和肺野裁剪，并用 validation 选择。

11.7 外部有效性威胁

RSNA 只使用 1707 张镜像可用子集，不代表完整挑战集；NIH 仅 130 张。项目没有独立医院前瞻性数据，没有按年龄、性别、设备或体位做亚组评价。Kermany 儿童人群与 RSNA 成人占比较高的人群差异很大。当前结论只能推广到这些公开数据的特定处理版本。

混合方案使用了 RSNA train/val，因此 RSNA test 是“已知目标域的留出评价”，不是完全外部验证。课程报告必须避免把它写成无监督域泛化。要证明对未知来源有效，需要至少一个未参与任何方法设计的足量第三数据集。

11.8 统计结论威胁

三个 seed 只能初步估计训练波动。患者 bootstrap 处理了同一患者多图相关，但 subject 解析误差会影响区间。多个模型、指标和方案会产生多重比较；本文没有用大量显著性检验挑选结果，而依赖预设 3 个百分点门槛、双域约束和效果方向。

ECE 依赖 10 个固定分箱，小样本和类别比例变化会影响数值。温度网格虽扩展到 20 并检查边界，仍是离散近似。validation 阈值跨 seed 变化明显，提示单一阈值不稳定。

11.9 工作量与课程价值

本项目的实际工作不只包括训练三个模型。更重要的部分是：发现并机器化检查患者交叉；修正配置漂移；建立患者级 manifest；完成 27 个严格基线评价集合、18 个稳健/混合核心训练-测试组合及校准、阈值和错误分析；把旧结果按证据等级重新分类；将网页与权重边界写清楚。

课程设计的价值体现在能解释为什么一个看似高分的模型仍可能不可靠，并用实验区分模型结构、数据覆盖、操作点和概率校准。负结果和停止规则也是工作成果，因为它们防止继续消耗算力追逐同一 test 最高值。

11.10 后续工作

第一，获取完整 RSNA 或另一个足量外部数据，预先冻结最终评价；第二，按 patient、view 和共病建立更严格标签；第三，比较保持纵横比、肺野分割和灰度标准

化；第四，在新的外部集合上评价 CORAL、GroupDRO 等方法；第五，增加五 seed 和配对 bootstrap 差值区间；第六，由医学人员盲法复核固定抽样错误案例。

只有这些条件逐步满足后，才适合讨论临床研究设计。当前网页不应扩展成患者使用工具。

11.11 对导师可能质疑的直接回应

11.11.1 为什么患者级新划分仍然高达 98%

新划分消除了同一 subject 跨集合，却仍是同一公开数据来源的随机分层。训练和 test 在年龄、人群、设备与处理流程上接近，任务本身也可能有明显类别特征。高内部结果只说明同来源未见患者分类较容易，RSNA 下降证明它不能推广成通用能力。

11.11.2 既然官方 test 有患者交叉，旧结果是否全部作废

不作废。预测和指标计算正确，也能复现公开目录 benchmark；问题是不能解释为患者独立估计。报告保留旧表并明确降级。科学修正不等于删除不利历史，而是改变其能支撑的论断。

11.11.3 为什么不把简单混合称为域泛化

因为训练直接使用 RSNA 标签。它是有监督多域训练或目标域适配。域泛化通常要求最终目标域在开发时不可见。准确命名比方法听起来是否高级更重要。

11.11.4 为什么不继续做更多模型和复杂算法

三模型内部/外部区间重叠，结构不是主要矛盾。简单混合已满足预设门槛，继续在同一 test 挑方法会增加适应风险。剩余时间用于多 seed、校准、阈值、错误审计和报告一致性，更能提高课程质量。

11.11.5 50 页是否仍在凑篇幅

新版正文没有使用一页一图，主要内容由 12 章文字、公式和表格组成。正文详细记录数据单位、实验职责、多 seed、置信区间、配置错误、负结果和有效性威胁。附录命令和产物索引位于参考文献之后，不计入正文目标。

11.12 研究诚信与协作边界

项目使用自动化工具辅助代码审查、实验执行、数字汇总和文稿组织，但研究判断必须由可检查产物支撑。报告不把未执行的 GroupDRO/CORAL 写成完成，不把旧单 seed 结果包装成新版多 seed，也不伪造医学人员复核。

所有自动生成文字都需要与 JSON、CSV 和日志核对。公开提交应保留代码、配置、manifest、审计报告和参考文献。若后续人工修改数字，必须重新运行一致性检查。团队成员应能说明各自负责的数据、模型、系统或写作内容，而不是只会复述最终摘要。

课程答辩中，最有说服力的不是宣称“导师挑不出问题”，而是主动指出患者交叉、标签差异和 test 适应，并展示如何修正。无法消除的限制应明确保留，这比过度承诺更符合研究训练目的。

第十二章 结论

本文围绕胸部 X 光肺炎二分类完成了从数据审计到外部评价的完整课程设计。项目首先验证旧结果能否复算，随后发现 Kermany 官方 train/test 有 170 个肺炎 subject ID 交叉。这个问题使旧 0.89–0.91 准确率只能作为公开目录复现。项目重新建立患者级划分，冻结 manifest 并通过患者、哈希和标签冲突门禁。

针对 RQ1，结论是患者级审计不可省略，但患者交叉不能被简单解释为旧分数虚高。新患者级随机划分内部更容易，三模型 accuracy 达到约 0.98。新旧 split 同时改变了独立性和分布难度，必须分别讨论。

针对 RQ2，DenseNet121、ConvNeXt-Tiny 与 ViT-B/16 在患者独立内部 test 上的差异很小。三 seed 集成 balanced accuracy 为 0.9727–0.9817，95% 区间重叠。没有证据支持某种结构在当前任务中具有明确优势。ViT 配置漂移曾造成明显欠拟合，也说明合理训练配方比只写架构名称更重要。

针对 RQ3，三模型直接迁移 RSNA 后 accuracy 降到约 0.66–0.68，主要错误是阴性误报。简单图像统计的来源分类 AUC 为 0.9551，证明两个来源存在明显风格差异。外部下降远大于模型结构差异，单一儿童胸片数据上的高分不能代表跨来源稳定性。

针对 RQ4，低成本强度扰动和标签平滑把 RSNA balanced accuracy 提高到约 0.7116，内部保持稳定，但外部 AUC 下降，只能称为部分改善。简单混合训练取得最完整结果：RSNA balanced accuracy 约 0.7645、AUC 约 0.8565，Kermany 内部 balanced accuracy 约 0.9684；域均衡波动更大且没有超过简单混合。混合收益依赖 RSNA 有监督数据，不等于对未知医院泛化。

校准分析进一步显示，Kermany-only 模型外部温度平均约 6.81，存在严重过度自信；简单混合外部温度约 1.56，概率漂移较小。validation 冻结阈值能改善 RSNA 操作点，但阈值跨 seed 不稳定。Grad-CAM 和错误网格只能帮助解释模型行为，不能作为病灶定位。

工程方面，项目补齐完整性审计、患者级数据生成、多 seed 聚合、温度范围检查和冻结阈值工具；网页支持单图推理与概率展示。所有输出仅用于课程设计和研究训练。当前证据不支持临床诊断、真实病灶定位或患者决策。

最终研究判断是：本项目的主要提升来自实验可信度和数据覆盖，而非网络数量。患者级独立、外部标签语义、统计不确定性和概率可靠性共同决定模型结论。把这些环节讲清楚，比在同一测试集继续寻找更高单次分数更符合课程设计训练目标。

参考文献

- [1] Gary S. Collins, Karel G. M. Moons, Paula Dhiman, et al. Tripod+ai statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378, 2024.
- [2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [3] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 1321–1330, 2017.
- [4] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4700–4708, 2017.
- [5] Daniel Kermany, Kang Zhang, and Michael Goldbaum. Labeled optical coherence tomography and chest x-ray images for classification, 2018.
- [6] Daniel S. Kermany, Michael Goldbaum, Wenjia Cai, et al. Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5):1122–1131.e9, 2018.
- [7] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, et al. A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42:60–88, 2017.
- [8] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11976–11986, 2022.

- [9] Karel G. M. Moons et al. Probast+ai: An updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388:e082505, 2025.
- [10] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 618–626, 2017.
- [11] George Shih, Carol C. Wu, Safwan S. Halabi, et al. Augmenting the national institutes of health chest radiograph dataset with expert annotations of possible pneumonia. *Radiology: Artificial Intelligence*, 1(1):e180041, 2019.
- [12] Baochen Sun and Kate Saenko. Deep coral: Correlation alignment for deep domain adaptation. In *ECCV Workshops*, pages 443–450, 2016.
- [13] Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri, and Ronald M. Summers. Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2097–2106, 2017.
- [14] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, 2018.
- [15] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. In *International Conference on Learning Representations*, 2018.

附录 A 复现与验收附录

A.1 环境安装

```
python -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
python -m pytest -q
```

A.2 患者级划分与审计

```
python scripts/prepare_kermany_grouped.py
python scripts/audit_integrity.py \
    --dataset data/processed/kermany_grouped_seed42 \
    --output results/integrity_audit_grouped.json
```

正式 manifest 为 data/splits/kermany_grouped_seed42.csv。重新生成前必须确认不会覆盖已用于正式结果的冻结版本。

A.3 严格训练示例

```
python scripts/train.py \
    --config configs/densenet121.yaml \
    --data-root data/processed/kermany_grouped_seed42 \
    --seed 42 \
    --json-output results/strict_train_densenet121_seed42.json
```

评价命令从 training summary 读取 best checkpoint，再分别评价 Kermany locked test 与 RSNA test。所有正式命令显式指定输出名并使用--no-update-latest，避免

通用 latest 文件覆盖证据。

A.4 结果聚合

```
python scripts/summarize_strict_results.py --bootstrap 2000
python scripts/evaluate_frozen_thresholds.py \
    --validation results/strict_predictions_rsna_val_\
densenet121_seed42.csv \
    --test results/strict_predictions_rsna_test_\
densenet121_seed42.csv \
    --output results/strict_operating_points_rsna_\
densenet121_seed42.json
```

A.5 校准

```
python scripts/analyze_calibration.py \
    --predictions results/strict_predictions_rsna_test_\
densenet121_seed42.csv \
    --calibration-predictions \
    results/strict_predictions_rsna_val_\
densenet121_seed42.csv \
    --temperature-max 20 \
    --json-output results/strict_calibration_rsna_\
densenet121_seed42.json
```

若 `at_search_boundary=true`，温度结果不得进入报告，应扩展范围后重算。

A.6 网页演示

```
python scripts/serve_patient_app.py \
    --checkpoint models/vit_b16_best.pt --device cpu
```

浏览器访问<http://127.0.0.1:7860>。公开 ViT 权重 SHA256 为：

78604698f504d8d96f5bdad9570608c77472e7625684cb13a6f222275c8381be

A.7 关键产物

产物	用途
results/integrity_audit.json	原数据和旧评价完整性审计
results/kernany_grouped_summary.json	患者级新划分统计与 manifest 哈希
results/strict_summary.json	三模型多 seed 与患者 bootstrap 汇总
results/domain_shift_diagnostic.json	来源分类与图像统计
results/robust_summary.json	低成本稳健训练汇总
results/mixed_strict_summary.json	简单混合和域均衡汇总
results/*calibration*.json	validation 温度与 test 校准结果
results/*operating_points*.json	validation 冻结阈值与 test 表现
reports/audit_review.md	书面审查、问题分级与修正

A.8 最终验收表

检查项	状态	证据
原结果能从预测 CSV 复算	通过	40 份评价无指标不一致
患者级新划分独立	通过	subject overlap=0
跨 split 精确重复	通过	SHA256 duplicate group=0
标签冲突	通过	conflict group=0
ViT 配置与权重设置一致	已修正	学习率 5e-5、batch 16、AMP 开启
核心模型多 seed	通过	三模型各 3 seeds
稳健与混合策略多 seed	通过	各方案 3 seeds
外部校准搜索不撞边界	通过	最大温度范围扩至 20
自动测试	通过	最终 pytest 记录
报告编译	以最终日志为准	XeLaTeX/BibTeX 无致命错误

检查项	状态	证据
临床边界	保留	摘要、正文、网页、结论一致